

Vztahy dvou proměnných a vizualizace

Podkladové čtenářské materiály k přednášce

6. října 2026

Obsah

1 Úvod	1
2 Výsledky učení	2
3 Jaká data budeme používat	2
4 První graf: délka ploutve a tělesná hmotnost	6
5 Co v grafu vidíme	7
6 Jaké proměnné budeme sledovat	8
7 Rozptýlení ve dvou směrech	9
7.1 Připomenutí: rozptyl a směrodatná odchylka jedné proměnné	10
8 Proč jsou data rozptýlená	11
9 Stejný graf, ale s viditelnými druhy	11
10 Jak se dvě proměnné pohybují společně?	12
10.1 Od kovariance k Pearsonově korelaci	15
11 Korelace jako stručný číselný popis	16
11.1 Stejná čísla, jiné grafy	18
12 Korelace není kauzalita	19
13 Jak typ proměnných určuje výběr grafu	20
13.1 Dvě numerické proměnné: délka ploutve a hmotnost	20
13.2 Kategoriální a numerická proměnná: druh a hmotnost	22
13.3 Druh a ostrov	26
13.4 Seřazené kategorie délky ploutve a hmotnost	29
13.5 Rychlá tabulka: který graf zvolit jako první?	32
14 Co zatím ještě nemůžeme tvrdit	33
15 Co bude následovat dál	33
16 Shrnutí	34
16.1 Závěrečná otázka	34
Slovníček pojmů	34

1 Úvod

V minulé lekci jsme se naučili určit, co představuje jeden řádek, rozpoznat typ jedné proměnné a zvolit pro ni vhodný souhrn a graf. V této lekci položíme druhou proměnnou vedle první. Stejná

pravidla stále platí, ale otázka se mění: nehledáme už jen tvar jednoho rozdělení, nýbrž vztah mezi dvěma znaky.

U živočichů často čekáme, že větší tělo bude souviset s většími orgány nebo končetinami. U tučňáků si proto můžeme položit jednoduchou otázku: mají jedinci s delší ploutví také větší tělesnou hmotnost? Tato otázka je vhodná pro první krok do světa vztahů dvou proměnných, protože nás nutí přemýšlet nejen o tvaru vzoru, ale i o variabilitě dat.

Otázka před prvním grafem

Co byste čekali ještě před tím, než se podíváme na data?

- **A:** Delší ploutev téměř vždy znamená vyšší hmotnost.
- **B:** Delší ploutev bude s vyšší hmotností souviset, ale ne dokonale.
- **C:** Délka ploutve a hmotnost spolu souviset nebudou.

Než budete číst dál, zkuste si vybrat, která odpověď vám připadá nejpravděpodobnější, a proč.

Odpověď: očekáváme nedokonalý vztah

Biologicky nejpravděpodobnější je **možnost B**: délka ploutve bude s tělesnou hmotností souviset, ale ne dokonale. Tělesné rozměry tučňáků jsou vzájemně provázány, ale každý jedinec je jiný — liší se druhem, pohlavím, věkem i podmínkami prostředí. Dokonalá shoda by v reálných biologických datech byla překvapivá.

2 Výsledky učení

Po prostudování této lekce budete schopni:

- přečíst bodový graf dvou numerických proměnných: směr, tvar a rozptýlení bodů
- vysvětlit, proč jsou biologická data rozptýlená i při zřetelném vztahu a co k popisu přidá korelace
- zvolit vhodný první graf podle typu dvojice proměnných
- rozlišit popis asociace od tvrzení o její příčině

3 Jaká data budeme používat

Dataset Palmer Penguins zachycuje měření dospělých tučňáků z Palmerova souostroví v letech 2007–2009. Jeden řádek odpovídá jednomu změřenému jedinci. Délka ploutve je v milimetrech a tělesná hmotnost v gramech; druh a ostrov označují skupiny. Původní data zveřejnil projekt Palmer Penguins pod CC0.

Soubor [palmer_penguins.csv](#) je součástí materiálů. Pro následující kód jej uložte do složky `data` ve svém projektu v R. Načtením vznikne tabulka `data_puvodni`; prázdná pole přečteme jako

chybějící hodnoty **NA**. Příkaz `dim()` ukáže počet řádků a sloupců, `head()` první tři řádky vybraných sloupců:

```
data_puvodni <-  
  read.csv(  
    file = "data/palmer_penguins.csv",  
    na.strings = ""  
  )  
dim(x = data_puvodni)
```

```
[1] 344  8
```

```
head(  
  x = data_puvodni[c("species", "flipper_length_mm", "body_mass_g")],  
  n = 3  
)
```

	species	flipper_length_mm	body_mass_g
1	Adelie	181	3750
2	Adelie	186	3800
3	Adelie	195	3250

Sloupec `species` obsahuje druh, `flipper_length_mm` délku ploutve a `body_mass_g` hmotnost. Zkontrolujeme, zda některé z obou měření chybí. Funkce `is.na()` označí chybějící hodnoty a `sum()` jejich počet:

```
sum(is.na(x = data_puvodni$flipper_length_mm))
```

```
[1] 2
```

```
sum(is.na(x = data_puvodni$body_mass_g))
```

```
[1] 2
```

Bod potřebuje známou délku i známou hmotnost **téhož** jedince. `complete.cases()` označí řádky s oběma hodnotami; hranaté závorky zachovají celé tyto řádky, aby se dvojice nerozpojily. V nové tabulce použijeme české názvy sloupců:

```

vec_uplne <-
  complete.cases(
    data_puvodni$flipper_length_mm,
    data_puvodni$body_mass_g
  )
data_pary <- data_puvodni[vec_uplne, ]
data_tucnaci <-
  data.frame(
    druh_tucnaka = data_pary$species,
    ostrov = data_pary$island,
    delka_ploutve_mm = data_pary$flipper_length_mm,
    hmotnost_g = data_pary$body_mass_g
  )

```

Původní soubor má 344 řádků. 2 řádky nemají obě měření; po jejich vynechání zůstává 342 úplných dvojic, tedy pozorování, u nichž známe délku ploutve i tělesnou hmotnost. V datech se objevují 3 druhy (Adelie, Chinstrap, Gentoo) ze 3 ostrovů. Znamé délky ploutve se pohybují od 172 do 231 mm a hmotnosti od 2700 do 6300 g. Kontrola rozsahu pomáhá odhalit zjevnou chybu jednotek nebo nesmyslnou hodnotu ještě před kreslením grafu.

Doplňující: jak vznikl soubor palmer_penguins.csv

Měření nasbírala Kristen Gorman s výzkumnou stanicí Palmer Station (program Long Term Ecological Research) na třech ostrovech Palmerova souostroví v Antarktidě v letech 2007–2009 ([Gorman, Williams a Fraser 2014](#)). Allison Horst, Alison Hill a Kristen Gorman data zpřístupnily v balíčku R palmerpenguins ([Horst a kol. 2020](#)) pod licencí CC0, takže je smíme volně používat a sdílet.

Soubor pro tuto lekci je přímým exportem tabulky `penguins` z balíčku `palmerpenguins` verze 0.1.1. Obsahuje všech 344 řádků a 8 původních sloupců (`species`, `island`, `bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`, `body_mass_g`, `sex`, `year`). Žádný řádek jsme nevynechali, nic nepřepočítali ani nepřejmenovali. Chybějící hodnota je v souboru prázdné pole, a proto ji při načtení převádíme na NA pomocí `na.strings = ""`. Chybí 2 délky ploutve, 2 hmotnosti a 11 údajů o pohlaví.

Soubor vytvořil skript `R/prepare_penguin_data.R`, který před uložením ověří verzi balíčku, počet řádků a sloupců i počty chybějících hodnot. Stejnou tabulku si můžete z balíčku uložit i v základním R; potřebujete k tomu nainstalovaný balíček `palmerpenguins`:

```


data_export <-
  as.data.frame(palmerpenguins::penguins)
write.csv(
  x = data_export,

```

```
file = "data/palmer_penguins.csv",  
row.names = FALSE,  
na = ""  
)
```

Pro výuku používáme samostatný soubor CSV místo balíčku proto, že se nezmění s novou verzí balíčku a v praxi stačí načíst jediný soubor pomocí `read.csv()`.

Na tomto datasetu je užitečné to, že biologický příběh dává smysl i bez složité statistiky. Delší ploutev může souviset s větší tělesnou velikostí, ale zároveň víme, že do výsledku vstupují i další zdroje rozdílů mezi jedinci.



Obrázek 1: Druhy tučňáků v datasetu Palmer Penguins. Ilustrace: Allison Horst.

Na obrázku výše jsou 3 druhy, se kterými budeme pracovat. Už z ilustrace je vidět, že se mezi nimi mohou lišit tělesné proporce. To je dobrá připomínka, že část rozptýlení bodů v bodovém grafu může souviset i s tím, že nesledujeme jediný homogenní typ jedince.

Jako první krok se ale na data podíváme co nejjednodušším způsobem: bez rozlišování druhů, jen jako na vztah mezi délkou ploutve a tělesnou hmotností.


Doplňující: sto bodů nemusí znamenat sto nezávislých informací

V této tabulce představuje každý řádek jiného změřeného tučňáka. V jiných studiích však může několik řádků patřit stejnému jedinci, mláďatům ze stejného hnízda, organismům ze stejné lokality nebo měřením ze stejného dne. Takové body mohou být navzájem podobnější než body z různých jedinců či lokalit.

Počet teček v grafu proto nemusí být totožný s počtem nezávislých informačních jednotek. Graf vztah stále užitečně ukáže, ale nejistotu nelze bezpečně počítat, jako by každý řádek přinášel zcela novou informaci. Hierarchická data, opakovaná měření a pseudoreplikaci budeme podrobně řešit v pozdější lekci.

4 První graf: délka ploutve a tělesná hmotnost

Nejprve si zobrazíme co nejjednodušší bodový graf. V tuto chvíli nechceme nic testovat ani odhadovat pomocí modelu. Chceme si všimnout, jak data vypadají.



Obrázek 2: Bodový graf délky ploutve (mm) a tělesné hmotnosti (g) v datasetu Palmer Penguins.

Tento první graf obsahuje 342 tučňáků. Stejná data si později vyzkoušíte číst i pomocí modelu.

Než si podobný graf nakreslíme sami, je užitečné v R rychle zkontrolovat prvních několik hodnot na obou osách:

```
head(  
  # Prvních šest délek ploutve – hodnoty na ose x  
  x = data_tucnaci$delka_ploutve_mm  
)
```


```
[1] 181 186 195 193 190 181
```

```
head(
  # Prvních šest hmotností – hodnoty na ose y
  x = data_tucnaci$hmotnost_g
)
```

```
[1] 3750 3800 3250 3450 3650 3625
```

Jakmile víme, které dvě proměnné chceme porovnat, můžeme tentýž první bodový graf rychle nakreslit v základním R:

```
plot(
  # Každý řádek dat vytvoří jeden bod se dvěma souřadnicemi
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
  # Popisky připomínají význam a jednotky obou os
  xlab = "Délka ploutve (mm)",
  ylab = "Tělesná hmotnost (g)",
  # Plné, průhledné body omezí překrývání
  pch = 16,
  col = rgb(red = 0.54, green = 0.54, blue = 0.54, alpha = 0.6)
)
```



5 Co v grafu vidíme

Než budete číst dál, zkuste se u grafu zastavit u tří krátkých otázek:

- Jakým směrem se oblak bodů zvedá nebo klesá?
- Jak široké je rozptýlení bodů kolem hlavního směru?

- Vidíte body, které se od většiny ostatních odlišují?

Odpověď: vztah je kladný, ale ne dokonalý


Celkový směr vztahu je zřetelně rostoucí: tučňáci s delší ploutví bývají těžší. Body ale neleží na jedné přímce; i při podobné délce ploutve se může tělesná hmotnost lišit o stovky gramů. Vztah v datech tedy opravdu vidíme, ale není natolik jednoduchý, aby se dal popsat jedinou „čistou“ čarou bez dalších otázek.

6 Jaké proměnné budeme sledovat

Po prvním pohledu na graf se teď vyplatí pojmenovat, co jsme vlastně zobrazili. Pracujeme se dvěma numerickými proměnnými:

- **osa x:** délka ploutve (anglicky *flipper length*) v milimetrech (`flipper_length_mm`)
- **osa y:** tělesná hmotnost (anglicky *body mass*) v gramech (`body_mass_g`)
- doplňkově kategoriální proměnná druh tučňáka (anglicky *species*; `species`)

Když jen popisujeme, zda dvě měření souvisejí, je přiřazení os libovolné. Kdybychom osy prohodili — délku svisle a hmotnost vodorovně — bodový mrak by vypadal jinak, ale směr i těsnost vztahu by zůstaly naprosto stejné. Pojmy *prediktor* a *odezva*, které popisují asymetrii os (jedna proměnná „vysvětluje“ druhou), patří k regresním modelům; ty si ukážeme v pozdějších lekcích.



Obrázek 3: Stejná data, dvě orientace os. Tvar mraku bodů se změní, ale směr i těsnost vztahu zůstanou stejné.

Bodový graf nám umožňuje podívat se současně na směr vztahu i na to, jak moc jsou hodnoty rozptýlené kolem hlavního vzoru.

Když ale sledujeme vztah dvou proměnných obecněji, typ grafu vybíráme podle toho, jaké proměnné máme k dispozici:


- **Dvě numerické proměnné:** hledáme směr vztahu a rozptýlení bodů. Dobrou první volbou je bodový graf (anglicky *scatter plot*).
- **Kategoriální a numerická proměnná:** hledáme rozdíly mezi skupinami a překryv rozdělení. Dobrou první volbou jsou body rozdělené do skupin, případně krabicevý graf (anglicky *box plot*) s body.
- **Dvě kategoriální proměnné:** sledujeme, kolik pozorování spadá do jednotlivých kombinací. Začít můžeme tabulkou četností nebo sloupcovým grafem (anglicky *bar chart*).

Obecné pravidlo tedy nezní jen „je v datech nějaký vztah?“, ale také „jaký graf vůbec dává pro tuto dvojici proměnných smysl?“ Ke všem třem situacím se vrátíme v závěru lekce. Do té doby zůstaneme u první z nich a budeme dál číst jeden bodový graf dvou numerických proměnných.

7 Rozptýlení ve dvou směrech

U jednorozměrných dat sledujeme rozptýlení jen v jednom směru, například jak moc se hodnoty hmotnosti liší kolem průměru. V bodovém grafu ale kolísají obě osy současně. Jeden tučňák může mít o něco delší ploutev než jiný a zároveň se může lišit i hmotností. Výsledkem je mrak bodů, který má šířku i výšku.

Na obrázku níže je stejný vztah zobrazený dvakrát. Vlevo si všímáme, že i při podobné délce ploutve mohou mít jedinci docela odlišnou hmotnost. Vpravo naopak vidíme, že i při podobné hmotnosti se může měnit délka ploutve.



Obrázek 4: Stejný bodový graf můžeme číst ve dvou směrech: při podobné délce ploutve se může lišit hmotnost a při podobné hmotnosti se může lišit délka ploutve. Zvýrazněné body leží uvnitř příslušného pásu.

To je důležité pro interpretaci. Když vidíme podlouhlý oblak bodů směřující zleva dole doprava nahoru, znamená to, že vedle celkového trendu stále existuje velké rozptýlení bodů. Dva jedinci s téměř stejnou délkou ploutve nemusí mít stejnou hmotnost a dva podobně těžcí jedinci nemusí mít stejnou dlouhou ploutev.

7.1 Připomenutí: rozptyl a směrodatná odchylka jedné proměnné

Z předchozí lekce připomeňme souhrny rozptýlení jedné proměnné: **výběrový rozptyl** (anglicky *sample variance*; zkráceně také jen **rozptyl**) a z něj odvozenou výběrovou směrodatnou odchylku (anglicky *sample standard deviation*, zkratka **SD**).

Výpočet výběrového rozptylu slovy: **od každé hodnoty odečteme průměr, odchylky umocníme na druhou, sečteme je a součet vydělíme počtem pozorování minus jedna**. Jako příklad použijeme malý vzorek 4 tučňáků druhu Adelie (průměr délky ploutve: 188,75 mm). Tabulka ukazuje délku ploutve každého z nich, odchylku od průměru a čtverec té odchylky:

Tuč- ňák	Délka ploutve (mm)	Odchylka od průměru (188,75 mm)	Čtverec odchylky (mm ²)
1	181	-7.75	60.0625
2	186	-2.75	7.5625
3	190	1.25	1.5625
4	198	9.25	85.5625

Stejný výpočet zapsaný názvy veličin:

$$\begin{aligned} & \text{výběrový rozptyl délky ploutve} \\ & \text{součet čtverců odchylek} \\ & \text{délek ploutví od průměru} \\ & = \frac{\text{počet tučňáků} - \text{jedna}}{\text{počet tučňáků} - \text{jedna}} \end{aligned}$$

Po dosazení délek ploutví a jejich průměru z tabulky:

$$\begin{aligned} \text{rozptyl} &= \frac{(181 - 188,75)^2 + (186 - 188,75)^2}{4 - 1} \\ &+ \frac{(190 - 188,75)^2 + (198 - 188,75)^2}{4 - 1} \\ &= \frac{60,0625 + 7,5625 + 1,5625 + 85,5625}{3} \\ &= \frac{154,75}{3} \approx 51,6 \text{ mm}^2 \end{aligned}$$

Směrodatná odchylka vrací rozptýlení do původních jednotek: je odmocninou výběrového rozptylu. Pro stejnou tabulku tedy platí:

$$\begin{aligned} \text{směrodatná odchylka} &= \sqrt{\text{výběrový rozptyl}} \\ &= \sqrt{\frac{154,75}{3}} \approx 7,18 \text{ mm} \end{aligned}$$

V obecném zápisu označíme délku ploutve x , její výběrový rozptyl s_x^2 a výběrovou směrodatnou odchylku s_x . Pro libovolný soubor n pozorování platí:

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_x = \sqrt{s_x^2}$$

Ve vzorci x_i označuje délku ploutve jednoho tučňáka, $\bar{x}$ průměrnou délku ploutve, n počet pozorování, s_x^2 výběrový rozptyl a s_x směrodatnou odchylku v původních jednotkách.

V celém souboru tučňáků vychází směrodatná odchylka délky ploutve přibližně 14.1 mm a tělesné hmotnosti přibližně 802 g. Tato čísla říkají, o kolik milimetrů nebo gramů se typický jedinec odchyluje od průměru celého souboru. Stejně odchylky od průměru použijeme později u kovariance, kde budeme sledovat dvě proměnné zároveň.

8 Proč jsou data rozptýlená

Variabilita v biologických datech není chyba, kterou bychom měli odstranit. Je to vlastnost reálného světa. Dva tučňáci mohou mít podobně dlouhou ploutev, ale lišit se druhem, pohlavím, věkem nebo celkovou tělesnou stavbou. K rozptýlení bodů přispívá i běžná nepřesnost měření a to, že žádný biologický vztah nebývá dokonale přesný.

Na tomto místě je užitečné rozlišit několik zdrojů variability, které se v grafu míchají dohromady:


- **biologické rozdíly mezi jedinci:** dva podobní jedinci nemusí být stejně těžcí ani stejně stavěni
- **rozdíly mezi skupinami:** část variability vzniká tím, že v jednom grafu spojujeme více druhů
- **nepřesnost a omezení měření:** reálná data nikdy nejsou úplně bez chyby
- **další nevysvětlené vlivy:** sledujeme jen malou část toho, co hmotnost organismu ovlivňuje

V našem datasetu se délka ploutve pohybuje přibližně od 172 do 231 mm a tělesná hmotnost od 2700 do 6300 g. Už z tohoto rozsahu je vidět, že nejde o několik téměř stejných jedinců, ale o biologicky pestrý soubor měření.

9 Stejný graf, ale s viditelnými druhy

Jeden ze zdrojů variability můžeme v datech přímo ukázat. Vráťme se ke stejnému bodovému grafu a odkryjeme ještě jednu informaci: druh tučňáka. Původní šedý oblak bodů se rozpadne na několik podskupin, které se částečně překrývají, ale zároveň mají vlastní polohu a vlastní rozptýlení.

Biologicky je to důležité: v původním bodovém grafu jsme viděli „jeden“ vztah, ale část tohoto vztahu je tvořena tím, že různé druhy mají různé typické kombinace délky ploutve a hmotnosti. Jinými slovy: část rozptýlení není jen náhodný šum, ale odráží i skutečnou strukturu dat.



Obrázek 5: Stejný bodový graf délky ploutve a tělesné hmotnosti, body obarvené podle druhu tučňáka.

Jakmile jsou druhy vidět, je snazší pochopit, proč byl původní oblak bodů tak široký. Část variability vzniká uvnitř druhů, ale část je dána i tím, že v jednom obrázku mícháme více biologicky odlišných skupin. To je přesně okamžik, kdy nám doplňková kategoriální proměnná pomůže lépe číst vztah dvou numerických proměnných.

Doplňující: souhrnný vztah se může lišit od vztahů uvnitř skupin


Šedý graf odpovídal na otázku, jak spolu délka ploutve a hmotnost souvisejí **napříč všemi tučňáky dohromady**. Barevný graf navíc dovoluje položit jinou otázku: jak spolu souvisejí **uvnitř každého druhu**. Tyto odpovědi nemusejí být stejné, protože celkový vzor kombinuje rozdíly mezi jedinci uvnitř druhů s rozdíly mezi typickými hodnotami jednotlivých druhů.

V pozdější lekci se k tomuto mísení vrátíme při tématu konfundování. Zde stačí bezpečné pravidlo: kdykoli barvy odhalí skupiny v jiných částech grafu, popište zvlášť celkový vzor a vzory uvnitř skupin. Zatím nepotřebujeme model ani nový výpočet; důležité je rozlišit dvě otázky, které lze položit nad stejnými body.

10 Jak se dvě proměnné pohybují společně?

Rozptýl jedné proměnné popisuje, jak moc jsou její hodnoty rozptýleny kolem průměru. U dvou proměnných nás navíc zajímá, zda se jejich odchylky od průměrů pohybují *společně*: mají tučňáci s nadprůměrně dlouhou ploutví také nadprůměrnou hmotnost?

Odpověď nejlépe uvidíme v grafu. Do bodového grafu přidáme dvě přerušované čáry — svislou v průměrné délce ploutve (200,9 mm) a vodorovnou v průměrné hmotnosti (4202 g). Graf se tím rozdělí na čtyři kvadranty:



Obrázek 6: Bodový graf tučňáků s průměrnou délkou ploutve a průměrnou hmotností (prerušované čáry), které dělí graf na čtyři kvadranty.

Přečtěte si obrázek

Ve kterých kvadrantech se shlukuje nejvíce bodů? Co to říká o tom, jakým směrem se délka ploutve a hmotnost pohybují spolu?

Odpověď: body převažují vpravo nahoře a vlevo dole

Nejvíce bodů leží vpravo nahoře a vlevo dole. Tučňáci s nadprůměrně dlouhou ploutví bývají i nadprůměrně těžcí a tučňáci s krátkou ploutví bývají lehčí. Odchytky obou proměnných od průměru tedy mají většinou stejné znaménko.

Pro každého tučňáka můžeme spočítat dvě odchytky — délky ploutve od jejího průměru a hmotnosti od jejího průměru — a vynásobit je. Znaménko tohoto součinu závisí na kvadrantu:

- **vpravo nahoře:** obě odchytky kladné — součin kladný
- **vlevo dole:** obě odchytky záporné — součin je stále kladný, protože $(-) \cdot (-) = (+)$
- **vpravo dole:** odchytky s opačnými znaménky — součin záporný
- **vlevo nahoře:** odchytky s opačnými znaménky — součin záporný

Když součiny všech tučňáků sečteme a vydělíme počtem pozorování minus jedna, dostaneme kovarianci (anglicky *covariance*). Rozhoduje znaménko i velikost jednotlivých součinů, ne jen počet bodů v kvadrantech: několik velmi vzdálených bodů může přispět víc než mnoho bodů blízko středu.

Výpočet kovariance slovy: **u každého tučňáka vynásobíme odchytku délky ploutve od jejího průměru odchylkou hmotnosti od jejího průměru, součiny sečteme a vydělíme**

počtem pozorování minus jedna. Pro stejný malý vzorek 4 tučňáků Adelie jako u rozptylu ukazuje tabulka všechny potřebné hodnoty:

Tuč- ňák	Odch. délky (mm), prům. 188,75 mm	Odch. hmotnosti (g), prům. 4050 g	Součin odchylek (mm·g)
1	-7.75	-300	2325.0
2	-2.75	-250	687.5
3	1.25	200	250.0
4	9.25	350	3237.5

Stejný výpočet zapsaný názvy obou proměnných:

$$\begin{aligned}
 & \text{výběrová kovariance délky ploutve a hmotnosti} \\
 & \quad \text{součet součinů odchylek} \\
 & \quad \text{délky ploutve a hmotnosti} \\
 & = \frac{\text{počet tučňáků} - \text{jedna}}{\text{počet tučňáků} - \text{jedna}}
 \end{aligned}$$

Po dosazení odchylek z tabulky:

$$\begin{aligned}
 \text{kovariance} &= \frac{(-7,75) \cdot (-300) + (-2,75) \cdot (-250) + (1,25) \cdot (200) + (9,25) \cdot (350)}{4 - 1} \\
 &= \frac{2325,0 + 687,5 + 250,0 + 3237,5}{3} \\
 &= \frac{6500}{3} \approx 2167 \text{ mm} \cdot \text{g}
 \end{aligned}$$

V obecném zápisu označíme délku ploutve x , hmotnost y a jejich výběrovou kovarianci $\text{cov}(x, y)$. Pro n pozorování:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Zde x_i označuje délku ploutve jednoho tučňáka, y_i jeho hmotnost, $\bar{x}$ a $\bar{y}$ příslušné průměry, n počet tučňáků a $\text{cov}(x, y)$ výběrovou kovarianci obou proměnných.

V celém souboru tučňáků převládá kladné součiny nad zápornými, takže kovariance vychází kladná: přibližně 9824 mm·g.

Kovariance ale závisí na jednotkách. Kdybychom přepočítali délku z milimetrů na centimetry a hmotnost ponechali v gramech, kovariance by se desetkrát zmenšila, přestože se vztah mezi tučňáky nijak nezměnil. Abychom vztah popsali číslem nezávislým na jednotkách, přepočítáme kovarianci pomocí směrodatných odchylek obou proměnných.

10.1 Od kovariance k Pearsonově korelaci

Na stejném malém vzorku 4 tučňáků si ukážeme plný výpočet Pearsonova korelačního koeficientu. Potřebujeme stejné součiny odchylek jako u kovariance a navíc čtverce odchylek obou proměnných:

Tuč- ňák	Odch. délky (mm)	Odch. hmot- nosti (g)	Součin od- chylek	Čtverec odch. délky	Čtverec odch. hmotnosti
1	-7.75	-300	2325.0	60.0625	90000
2	-2.75	-250	687.5	7.5625	62500
3	1.25	200	250.0	1.5625	40000
4	9.25	350	3237.5	85.5625	122500

Výpočet zapsaný názvy veličin:

$$\begin{aligned}
 & \text{Pearsonův korelační koeficient} \\
 & \text{součet součinů odchylek} \\
 & \text{délky ploutve a hmotnosti} \\
 = & \frac{\text{součet součinů odchylek}}{\sqrt{\text{součet čtverců odchylek délky ploutve}} \cdot \sqrt{\text{součet čtverců odchylek hmotnosti}}}
 \end{aligned}$$

Součty čtverců získáme ze dvou posledních sloupců tabulky. Pro délku ploutve rozepíšeme všechny čtyři příspěvky:

$$\begin{aligned}
 & (-7,75)^2 + (-2,75)^2 + (1,25)^2 + (9,25)^2 \\
 & = 60,0625 + 7,5625 + 1,5625 + 85,5625 \\
 & = 154,75 \text{ mm}^2
 \end{aligned}$$

Stejně postupujeme u hmotnosti:

$$\begin{aligned}
 & (-300)^2 + (-250)^2 + (200)^2 + (350)^2 \\
 & = 90000 + 62500 + 40000 + 122500 \\
 & = 315000 \text{ g}^2
 \end{aligned}$$

Součet součinů odchylek vydělíme odmocninou součinu těchto dvou součtů:

$$\begin{aligned}
\text{korelace} &= \frac{(-7,75) \cdot (-300) + (-2,75) \cdot (-250) + (1,25) \cdot (200) + (9,25) \cdot (350)}{\sqrt{154,75} \cdot \sqrt{315000}} \\
&= \frac{2325,0 + 687,5 + 250,0 + 3237,5}{\sqrt{154,75} \cdot \sqrt{315000}} \\
&= \frac{6500}{\sqrt{154,75} \cdot \sqrt{315000}} \approx 0,93
\end{aligned}$$

Tímto přepočtem dostaneme Pearsonův korelační koeficient, který leží vždy v intervalu $[-1, +1]$. Je to totéž jako vydělit kovarianci součinem směrodatných odchylek obou proměnných: kovariance i oba rozptyly obsahují stejné dělení počtem pozorování minus jedna, které se ve zlomku vykrátí. Pro čtyři tučňáky z tabulky vyšlo 0,93. V celém souboru tučňáků vychází přibližně 0,87 – přesně stejný výsledek jako přímý výpočet (0,87), jen odvozený jinou cestou.

Pearsonův korelační koeficient označujeme symbolem r . Obecně jej můžeme zapsat bez jednotek takto:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Zde r označuje Pearsonův korelační koeficient, x_i a y_i dvojici hodnot jednoho tučňáka, $\bar{x}$ a $\bar{y}$ průměry obou proměnných a n počet pozorování. Čitatel shrnuje společný pohyb odchylek; jmenovatel jej převede na bezrozměrné měřítko.

11 Korelace jako stručný číselný popis

Graf je vždy první krok, ale někdy chceme vztah dvou numerických proměnných shrnout i číslem. K tomu slouží korelace. Pearsonovo r jsme před chvílí odvodili z kovariance – vydělíme kovarianci součinem směrodatných odchylek a dostaneme číslo v rozsahu $[-1, +1]$. V datech tučňáků vychází přibližně 0,87.

Druhou běžnou možností je **Spearmanova korelace** (anglicky *Spearman's rank correlation*). Hodnoty obou proměnných nejprve nahradí jejich pořadím (nejkratší ploutev = 1, druhá nejkratší = 2, ...) a korelaci spočítá z těchto pořadí. Ptá se tedy, zda vztah stále roste nebo stále klesá, i když body neleží na přímce; takovému vztahu se odborně říká monotónní. U tučňáků vychází Spearmanova korelace přibližně 0,84.

V R si obě čísla spočítáme přímo nad stejnými dvěma sloupci, které jsme předtím použili pro bodový graf:

```
cor(
  # Pearsonova korelace shrnuje lineární vztah původních hodnot
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
```

```
method = "pearson"
)
```


```
[1] 0.8712018
```

```
cor(
  # Spearmanova korelace místo hodnot porovnává jejich pořadí
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
  method = "spearman"
)
```

```
[1] 0.8399741
```

Takto dostaneme dvě stručná čísla, která shrnují tutéž biologickou otázku trochu jiným způsobem: Pearson zdůrazňuje lineární vztah, Spearman pořadí hodnot.

Na schématu níže jsou čtyři typické situace. Kladný vztah používá skutečná měření tučňáků; záporný vztah, zakřivený vztah a příklad bez zřetelné souvislosti jsou zkonstruované výukové ilustrace, nikoli další terénní měření. Všimněte si, jak se mění tvar bodového mraku a kdy se Pearsonova a Spearmanova korelace od sebe vzdálí.



Obrázek 7: Čtyři typické situace korelace: silný kladný vztah tučňáků, žádná zřetelná souvislost, silný záporný vztah a stále rostoucí, ale zakřivený vztah. U každého panelu jsou hodnoty Pearsonovy a Spearmanovy korelace.

- **Pearsonova korelace:** pracuje s původními hodnotami, shrnuje, jak těsně body leží podél přímky, a bývá citlivější na odlehlá pozorování.

- **Spearmanova korelace:** pracuje s pořadím hodnot, shrnuje, zda vztah stále roste nebo stále klesá, a bývá vůči odlehlým pozorováním odolnější.


Když body tvoří přibližně přímkový oblak bez výrazně vzdálených pozorování, bývají obě korelace podobné — tak je tomu u tučňáků. V zakřiveném panelu ale Spearmanova korelace zůstává téměř 1, zatímco Pearsonova je nižší: pořadí hodnot roste téměř dokonale, ale body neleží na přímce. Rozdíl mezi oběma čísly tak sám o sobě upozorňuje, že vztah není přímkový nebo že jej ovlivňuje několik vzdálených bodů.

V této lekci je důležité hlavně to, že obě čísla mají podpůrnou roli. Nenahrazují graf ani biologickou interpretaci. Pomáhají jen stručně vyjádřit, že delší ploutve bývají spojeny s vyšší hmotností a že tento vztah je v datech zřetelný i po převodu do číselné podoby.

Doplňující: podobná čísla, různé grafy

11.1 Stejná čísla, jiné grafy

Čtyři malé soubory známé jako **Anscombův kvartet** mají velmi podobné průměry, rozptyly i Pearsonovu korelaci. Nejdřív se podívejte na body: co byste o vztahu řekli v každém panelu, kdybyste znali jen společné číslo r ?



Obrázek 8: Anscombův kvartet: čtyři bodové grafy se skoro stejnými souhrnnými čísly, ale odlišným tvarem vztahu. Data jsou součástí R.

Soubor	Průměr x	Průměr y	Rozptyl x	Rozptyl y	Pearsonovo r
A	9,00	7,50	11,00	4,13	0,82
B	9,00	7,50	11,00	4,13	0,82
C	9,00	7,50	11,00	4,12	0,82
D	9,00	7,50	11,00	4,12	0,82

Čísla jsou téměř stejná, ale panely nejsou zaměnitelné: v jednom se vztah zakřivuje, jinde jej výrazně ovlivňuje jediný bod. Proto začínáme grafem a teprve pak čteme korelaci nebo další souhrn.

12 Korelace není kauzalita

V této chvíli už umíme vztah dvou numerických proměnných dobře popsat slovně i číslem. Je ale důležité nepřekročit hranici toho, co nám korelace opravdu říká. Korelace popisuje, že se dvě proměnné mění společně, ale sama o sobě ještě neukazuje, která proměnná je příčinou druhé.

U tučňáků tedy můžeme bezpečně říct, že delší ploutev bývá spojena s vyšší hmotností. Nemůžeme ale jen z korelace uzavřít, že změna délky ploutve přímo způsobuje změnu hmotnosti. Část vztahu může vznikat i tím, že obě proměnné souvisejí s celkovou velikostí těla nebo s druhem.

Modelování umožní vztah popsat v původních jednotkách a zohlednit další sledované proměnné. Příčinný výklad však závisí na designu studie a předpokladech, které samotný graf, korelace ani přidání modelu nezaručí. Také korelační odhad má nejistotu; její vyjádření není vyhrazené modelům a budeme se mu věnovat v další části kurzu.

Co je správná interpretace?

- **A:** Kladná korelace znamená, že jsme prokázali příčinný vztah.
- **B:** Kladná korelace znamená, že proměnné spolu souvisejí, ale příčinu musíme řešit opatrněji.
- **C:** Korelace je jen technické číslo bez biologického významu.

Odpověď: korelace sama neurčuje příčinu

Správně je **B**. Korelace je biologicky užitečný souhrn společného vzoru v datech, ale sama ještě nerozlišuje přímou příčinu od dalších možných vysvětlení.

13 Jak typ proměnných určuje výběr grafu


Typ grafu nevybíráme podle toho, co je „hezčí“, ale podle toho, jaký vztah mezi proměnnými chceme přechít. Jinak čteme dvě numerické proměnné na osách, jinak porovnáváme skupiny proti číslům a jinak sledujeme složení dvou kategoriálních proměnných.

Jako rychlá pomůcka pomáhají dvě otázky:

- Jsou obě proměnné numerické?
- Nebo jedna z nich hlavně rozděluje pozorování do skupin?

13.1 Dvě numerické proměnné: délka ploutve a hmotnost

Právě proto jsme v této lekci začali bodovým grafem (anglicky *scatter plot*). Když jsou obě proměnné numerické, bývá bodový graf nejlepší první volbou: každý bod nese dvojici hodnot a my můžeme najednou číst směr vztahu, rozptýlení bodů, možné shluky i odlehlá pozorování.



Obrázek 9: Dvě numerické proměnné: bodový graf je přirozený první krok, protože každý bod nese dvojici hodnot současně.


U tučňáků jsme v něm viděli, že delší ploutve bývají spojené s vyšší hmotností, ale také že vztah není dokonale těsný. Právě to je důvod, proč bodový graf nepřeskakovat. Žádné jediné číslo nám neukáže tvar oblaku bodů tak přímo.

Když ale chceme ve stejných datech zvýraznit jinou vlastnost vztahu, můžeme použít i několik dalších variant. Každá z nich ukazuje něco trochu jiného.

Hladký trend (*fitted trend line*)

Čára pomáhá rychle přechít hlavní směr vztahu, ale body pořád zůstávají viditelné.


Bodový graf s vyznačeným hlavním trendem



Hustota v mřížce (2D histogram)


Když je bodů hodně, můžeme místo jednotlivých bodů ukázat, kde se měření hromadí nejvíce.

Mřížka hustoty místo jednotlivých bodů




Vrstevnice hustoty (2D density)

Místo počtů v mřížce můžeme ukázat hladké vrstevnice: čím tmavší oblast, tím víc tučňáků má podobnou kombinaci délky ploutve a hmotnosti.




Po druzích v panelech (*small multiples*)

Rozdělení do panelů pomáhá odlišit, co je společný trend a co je rozdíl mezi skupinami.



13.2 KATEGORIÁLNÍ A NUMERICKÁ PROMĚNNÁ: DRUH A HMOTNOST

Jakmile nás začne zajímat přímo vztah mezi druhem a tělesnou hmotností, bodový graf už není nejpřirozenější první volbou. Teď totiž nesrovnáváme dvě číselné osy, ale kategoriální proměnnou určující skupiny a numerickou proměnnou, která se mezi nimi porovnává.



Než si přečtete vysvětlení, zkuste si v grafu najít tři věci:

- Který druh leží typicky nejvýš?
- Kde se rozdělení hmotnosti mezi druhy překrývá a kde už méně?
- Je rozptýlení uvnitř jednotlivých druhů malé, nebo i v rámci jednoho druhu zůstává docela velké?

Odpověď: rozdíly mezi druhy i uvnitř druhů

Tučňáci druhu Gentoo leží typicky nejvýš. Adelie a Chinstrap se vzájemně překrývají více. I uvnitř každého druhu je viditelné rozptýlení — takže ani znalost druhu sama o sobě nestačí k přesnému určení hmotnosti konkrétního jedince.


Na tomto grafu nečteme směr vztahu jako v bodovém grafu. Místo toho sledujeme, zda se rozdělení tělesné hmotnosti mezi druhy překrývá, nebo zda některé skupiny leží typicky výš či níž. I to je vztah dvou proměnných: hodnota jedné proměnné se mění podle úrovně druhé.

Na první pohled se zdá, že tučňáci druhu Gentoo leží typicky výš než Adelie a Chinstrap. Zároveň ale skupiny nejsou úplně oddělené a i uvnitř každého druhu zůstává viditelné rozptýlení. Pro tuto kombinaci typů proměnných je proto často přirozenější krabicový graf (anglicky *box plot*) nebo body rozdělené do skupin než klasický bodový graf.

Totéž srovnání ale můžeme nakreslit i jinak podle toho, zda chceme zdůraznit jednotlivé body, šířku skupin nebo jen jejich shrnutí.


Samotné body (*beeswarm plot*)

Nejlépe ukazují jednotlivá měření a překryv skupin, ale hůře shrnují jejich střed.




Krabice bez bodů (*box plot*)

Rychle shrnou polohu a překryv skupin, ale skryjí jemnější tvar rozložení uvnitř každého druhu.




Šířka rozložení (*violin plot*)

Hladký obrys dává lepší představu o tom, kde je v každé skupině více a méně hodnot.




Počty v intervalech (*stacked histogram*)

Skládaný histogram ukazuje skutečné počty tučňáků v intervalech hmotnosti; barva rozlišuje druh.



Relativní složení (*stacked density*)


Skládaná hustota neukazuje počty, ale relativní složení: který druh převažuje při dané hmotnosti.



Další užitečný případ jsou dvě kategoriální proměnné najednou.

13.3 Druh a ostrov

Jinou situaci dostaneme, když obě proměnné rozdělují data do skupin. V datech tučňáků je takovou dvojicí druh a ostrov, na kterém byl jedinec změřen. Teď nečteme číselné hodnoty na ose, ale počty a složení kombinací kategorií.



Obrázek 10: Složení druhů na třech ostrovech: každý sloupec představuje 100 % tučňáků změřených na daném ostrově.

U takového grafu nás zajímá něco jiného než u boxplotu. Neptáme se, jaká je typická hodnota, ale jaké je zastoupení druhů na jednotlivých ostrovech. Proto se zde hodí proporční skládaný sloupcový graf (anglicky *proportional stacked bar chart*): každý ostrov má stejnou výšku 100 % a my snadno porovnáváme podíly.

Než si přečtete vysvětlení, zkuste odpovědět:

- Na kterém ostrově jsme zaznamenali jen jeden druh?
- Který druh se v datech vyskytuje na všech třech ostrovech?
- Co z tohoto grafu nevyčtete o tom, kolik tučňáků bylo na jednotlivých ostrovech změřeno?


Odpověď: složení se mezi ostrovy liší, počty graf skrývá

Na ostrově Torgersen jsme zaznamenali jen druh Adelie, který jako jediný žije na všech třech ostrovech. Gentoo se v datech objevuje jen na ostrově Biscoe a Chinstrap jen na ostrově Dream. Proporční graf ale skrývá velikost skupin: všechny sloupce mají stejnou výšku, přestože na Biscoe bylo změřeno 167 tučňáků a na Torgersen jen 51.

Stejná dvojice kategoriálních proměnných se dá zobrazit i jinými způsoby podle toho, zda chceme zdůraznit podíly, absolutní počty nebo přehled celé tabulky najednou.


Proporce (*proportional stacked bar chart*)

Když mají všechny sloupce stejnou výšku, snadno porovnáváme složení ostrovů mezi sebou.




Absolutní počty (*grouped bar chart*)

Vedle sebe postavené sloupce se hodí tehdy, když nás zajímá i velikost jednotlivých skupin, nejen jejich složení.



Tepelná mapa (*heat map*)


Když chceme rychle přehledně celou tabulku kombinací, je praktické převést ji na barevnou mřížku.



Dlaždicový graf (*waffle chart*)

Každý čtvereček představuje jednoho tučňáka. Graf tak ukáže složení i velikost skupin najednou: ostrov s více změřenými tučňáky má více čtverečků.


Dlaždicový graf: každý čtvereček je jeden tučňák



Bublinové počty (*bubble chart*)

Plocha každé bubliny odpovídá počtu tučňáků v kombinaci druhu a ostrova. Graf je efektní, ale porovnávat plochy je pro oko těžší než porovnávat délky sloupců.

Stejná tabulka jako plocha bublin




Ještě jiný případ je seřazená osa proti numerické proměnné.

13.4 Seřazené kategorie délky ploutve a hmotnost

Kategoriální proměnná může mít i přirozené pořadí. Abychom si to ukázali na stejných datech, rozdělíme délku ploutve do tří seřazených kategorií: kratší, střední a delší (každá obsahuje přibližně třetinu tučňáků). Jde jen o ukázkou práce s ordinální proměnnou; pro spojitou proměnnou bychom vztah s hmotností četli raději přímo v bodovém grafu. Stejný typ grafu použijeme i pro přirozeně seřazené biologické škály, například malý–střední–velký.

Kategorii délky ploutve dáme na osu x a hmotnost jako numerickou proměnnou na osu y. V takové chvíli je užitečný opět krabicový graf (anglicky *box plot*), ale tentokrát je zásadní, že pořadí kategorií na ose nese informaci.

Ordinální + numerická proměnná: záleží i na pořadí kategorií



Než si přečtete vysvětlení, zkuste si všimnout tří věcí:


- Posouvá se typická hmotnost od kratších ploutví k delším?
- Kde se skupiny ještě překrývají a kde už méně?
- Co by se ztratilo, kdybychom pořadí kategorií na ose x promíchali?

Tentokrát neporovnáváme nepojmenované skupiny, ale seřazené stupně. Proto má smysl sledovat, zda se s rostoucí kategorií posouvá i typická hmotnost. Kdybychom pořadí kategorií na ose promíchali, velká část sdělení grafu by se ztratila.

I zde ale existuje více rozumných variant. Některé lépe ukazují jednotlivá pozorování, jiné zase co nejstručněji souhrn podle pořadí.


Samotné body (*beeswarm plot*)

Když chceme ponechat všechna měření viditelná, stačí je rozložit do stran v jednotlivých kategoriích.




Spojené středy (*line plot of group summaries*)

Pokud chceme co nejrychleji číst posun od kratších k delším kategoriím, pomůže jednoduché spojení typických hodnot.



Šířka rozložení (*violin plot*)

Hladký obrys pomůže ukázat, kde jsou v každé seřazené skupině data koncentrovaná a kde naopak řidká.



13.5 Rychlá tabulka: který graf zvolit jako první?

Tabulka zahrnuje také souhrny jedné proměnné z předchozí lekce: histogram pro rozdělení číselných hodnot a sloupkový graf pro četnosti kategorií. U seřazených skupin můžeme porovnat mediány; jednotlivá měření přitom nesmíme zaměnit za jejich souhrn.

Typ proměnných	Co chceme zobrazit	Dobrý první graf	Co v něm hledat
jedna numerická	Jak vypadá rozdělení jedné numerické proměnné	histogram	tvar rozdělení, rozptýlení, odlehlá pozorování
jedna kategoriální	Kolik pozorování padá do jednotlivých skupin	sloupkový graf	četnosti, podíly, nerovnováha skupin
numerická × numerická	Jak spolu souvisejí dvě numerické proměnné	bodový graf	směr, tvar, rozptýlení, odlehlá pozorování
kategoriální × numerická	Jak se liší numerická proměnná mezi skupinami	body ve skupinách; boxplot + body	rozdíly mezi skupinami, překryv, rozptýlení uvnitř skupin
kategoriální × kategoriální	Jak se kombinují dvě skupinové proměnné	tabulka četností; sloupce počtů nebo podílů	složení kombinací, počty vs. podíly
ordinální × numerická	Jak se mění numerická proměnná napříč seřazenými stupni	boxplot se seřazenou osou	posun mediánu, překryv, monotónní trend

Tahle tabulka není seznam všech možných grafů. Je to bezpečný první krok pro situaci, kdy si nejdřív potřebujeme ujasnit, co vlastně porovnáváme. Až potom má smysl přidávat další vrstvy, jemnější styl nebo formálnější model.

14 Co zatím ještě nemůžeme tvrdit


Častý omyl zní: v grafu je vidět vztah, takže jsme prokázali příčinu. Graf ukázal směr a tvar vztahu a korelace vyjádřila jeho těsnost číslem. Tím však neodlišíme přímý účinek jedné proměnné od společné příčiny, například druhu nebo celkové velikosti těla. Pro tvrzení o příčině potřebujeme vhodný design studie a obhajitelné předpoklady; samotné přidání modelu příčinu neprokáže.

Správná formulace pro tuto chvíli je skromnější: v datech vidíme vzor, který je biologicky smysluplný a který chceme v dalších lekcích popsat přesněji.

15 Co bude následovat dál

Korelace již shrnula směr a těsnost vztahu číslem bez jednotek. V další lekci navážeme lineárním modelem: vztah popíšeme v původních jednotkách a budeme se ptát, o kolik gramů se typická hmotnost liší při rozdílu jednoho milimetru délky ploutve. Odhady a jejich nejistotu rozvineme v další části kurzu.

Palmer Penguins ale nabízí i další proměnné, které se budou hodit pro pozdější příklady, například délku a hloubku zobáku. Stejná logika výběru grafu a interpretace vztahu se pak bude dát použít i na jiné biologické otázky než jen na délku ploutve a hmotnost.



Obrázek 11: Schéma měření délky a hloubky zobáku v datech Palmer Penguins. Ilustrace: Allison Horst.

16 Shrnutí

- Pro dvě numerické proměnné je první volbou bodový graf; nejprve jej dobře přečteme a teprve potom přidáváme další vrstvy informace.
- V bodovém grafu čteme současně směr vztahu i rozptýlení bodů ve dvou směrech.
- Biologická data jsou rozptýlená i při zřetelném vztahu; doplňková kategoriální proměnná, například druh, může ukázat, že část této variability odráží skutečnou strukturu dat.
- Korelace je stručný číselný popis vztahu dvou numerických proměnných, ale nenahrazuje graf ani interpretaci.
- Typ grafu vybíráme podle dvojice proměnných; biologická otázka rozhodne, co má graf zvýraznit.
- Viditelný vzor ani korelace ještě nejsou důkazem příčiny.

16.1 Závěrečná otázka

Někdo vám ukáže jen číslo $r = 0,87$ pro délku ploutve a hmotnost tučňáků, bez grafu, a napíše titulky „Delší ploutev, těžší tučňák“. Jaké tři otázky mu položíte, než titulku uvěříte?

Možné otázky

Jak vypadá bodový graf — leží body podél přímky, nebo tvoří křivku či oddělené shluky? Jsou v datech skupiny, například druhy, které mohou vztah vytvářet nebo měnit? Kolik pozorování data obsahují a jak byla měřena? A tvrdí titulky jen souvislost, nebo i příčinu?

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>