

Vztahy dvou proměnných, vizualizace, pravděpodobnost

Podkladové čtenářské materiály k přednášce

26. února 2026

Obsah

1 Úvod	2
2 Co si z této lekce odnést	2
3 Jaká data budeme používat	3
4 První graf: délka ploutve a tělesná hmotnost	3
5 Co v grafu vidíme	5
6 Jaké proměnné budeme sledovat	5
7 Rozptyl ve dvou směrech	7
8 Proč jsou data rozptýlená	8
9 Kovariance: jak se dvě proměnné pohybují společně	8
10 Korelace jako stručný číselný popis	11
11 Korelace není kauzalita	13
12 Stejný graf, ale s viditelnými druhy	13
13 Jak typ proměnných určuje výběr grafu	14
13.1 Dvě numerické proměnné: délka ploutve a hmotnost	14
13.1.a Hladký trend	15
13.1.b Hustota v mřížce	15
13.1.c Po druzích	16
13.2 Kategoriální a numerická proměnná: druh a hmotnost	16
13.2.a Samotné body	17
13.2.b Krabice bez bodů	18
13.2.c Šířka rozložení	18
13.3 Druh a kategorie délky ploutve	19
13.3.a Proporce	20
13.3.b Absolutní počty	20
13.3.c Tepelná mapa	21
13.3.d Dlaždicový graf	21
13.4 Seřazené kategorie délky ploutve a hmotnost	22
13.4.a Samotné body	23
13.4.b Spojené středy	23
13.4.c Šířka rozložení	23

13.5 Rychlá tabulka: který graf zvolit jako první?	24
14 Co zatím ještě nemůžeme tvrdit	25
15 Co bude následovat dál	25
16 Shrnutí	26
Slovníček pojmů	26

1 Úvod

U živočichů často čekáme, že větší tělo bude souviset s většími orgány nebo končetinami. U tučňáků si proto můžeme položit jednoduchou otázku: mají jedinci s delší ploutví také větší tělesnou hmotnost? Tato otázka je vhodná pro první krok do světa vztahů dvou proměnných, protože nás nutí přemýšlet nejen o tvaru vzoru, ale i o variabilitě dat.

🔍 Otázka před prvním grafem

Co byste čekali ještě před tím, než se podíváme na data?

- Delší ploutev téměř vždy znamená vyšší hmotnost.
- Delší ploutev bude s vyšší hmotností souviset, ale ne dokonale.
- Délka ploutve a hmotnost spolu souviset nebudou.

Než budete číst dál, zkuste si vybrat, která odpověď vám připadá nejpravděpodobnější, a proč.

💡 Odpověď

Biologicky nejpravděpodobnější je **možnost B**: délka ploutve bude s tělesnou hmotností souviset, ale ne dokonale. Tělesné rozměry tučňáků jsou vzájemně provázány, ale každý jedinec je jiný – liší se druhem, pohlavím, věkem i podmínkami prostředí. Dokonalá shoda by v reálných biologických datech byla překvapivá.


2 Co si z této lekce odnést

- vybrat vhodný graf pro vztah dvou proměnných
- popsát, jaký vzor v datech vidíme a co zatím říct nemůžeme
- vysvětlit, proč jsou reálná biologická data rozptýlená i tehdy, když v nich pozorujeme zřetelný směr
- stručně popsát vztah dvou numerických proměnných pomocí korelace a vysvětlit, proč se Pearson a Spearman mohou lišit
- připravit si půdu pro další lekce, kde budeme vztah dvou proměnných popisovat modelem

3 Jaká data budeme používat

Budeme pracovat s datasety Palmer Penguins, které shrnují měření tučňáků z oblasti Palmer Station v Antarktidě. Pro tuto lekci jsme ponechali 342 pozorování, u nichž známe délku ploutve, tělesnou hmotnost a druh. V datech se objevují 3 druhy: Adelie, Chinstrap, Gentoo.

Na tomto datasetu je užitečné to, že biologický příběh dává smysl i bez složité statistiky. Delší ploutev může souviset s větší tělesnou velikostí, ale zároveň víme, že do výsledku vstupují i další zdroje rozdílů mezi jedinci.




Obrázek 1: Druhy tučňáků v datasetu Palmer Penguins. Ilustrace: Allison Horst.

Na obrázku výše jsou 3 druhy, se kterými budeme pracovat. Už z ilustrace je vidět, že se mezi nimi mohou lišit tělesné proporce. To je dobrá připomínka, že část rozptylu v bodovém grafu může souviset i s tím, že nesledujeme jediný homogenní typ jedince.

Jako první krok se ale na data podíváme co nejjednodušším způsobem: bez rozlišování druhů, jen jako na vztah mezi délkou ploutve a tělesnou hmotností.

4 První graf: délka ploutve a tělesná hmotnost

Nejprve si zobrazíme co nejjednodušší bodový graf. V tuto chvíli nechceme nic testovat ani odhadovat pomocí modelu. Chceme si všimnout, jak data vypadají.



Obrázek 2: Bodový graf délky ploutve (mm) a tělesné hmotnosti (g) v datasetu Palmer Penguins.

Tento první graf obsahuje 342 tučňáků a ukazuje stejná data, která si studenti později vyzkoušejí číst i pomocí modelu.

Než si podobný graf nakreslíme sami, je užitečné v R rychle zkontrolovat prvních několik hodnot na obou osách:

```
head(
  x = data_tucnaci$delka_ploutve_mm
)
```

```
[1] 181 186 195 193 190 181
```


```
head(
  x = data_tucnaci$hmotnost_g
)
```

```
[1] 3750 3800 3250 3450 3650 3625
```

Jakmile víme, které dvě proměnné chceme porovnat, můžeme tentýž první bodový graf rychle nakreslit v základním R:

```
plot(
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
  xlab = "Délka ploutve (mm)",
  ylab = "Tělesná hmotnost (g)",
  pch = 16,
```

```
col = rgb(red = 0.54, green = 0.54, blue = 0.54, alpha = 0.6)
)
```



5 Co v grafu vidíme

Na první pohled je vidět rostoucí mrak bodů: tučňáci s delší ploutví bývají častěji těžší. To je důležitý první poznatek. Zároveň ale body neleží na jedné přímce. I při podobné délce ploutve se může tělesná hmotnost lišit o stovky gramů.

Před dalším čtením se zkuste zastavit u tří krátkých otázek:

- Kde je vztah mezi proměnnými nejnápadněji viditelný?
- Jak velký je rozptyl kolem hlavního směru?
- Vidíte body, které se od většiny ostatních odlišují?

i Odpověď

Celkový směr vztahu je zřetelně rostoucí: tučňáci s delší ploutví bývají těžší. Kolem tohoto trendu ale zůstává dost široký oblak bodů. Vztah v datech vidíme, ale není natolik jednoduchý, aby se dal popsat jedinou čarou bez dalších otázek.


Základní odpověď je tato: celkový směr vztahu je zřetelně rostoucí, ale kolem něj zůstává dost široký oblak bodů. Už teď tedy víme dvě důležité věci zároveň: vztah v datech opravdu vidíme, ale není natolik jednoduchý, aby se dal popsat jedinou „čistou“ čarou bez dalších otázek.

6 Jaké proměnné budeme sledovat

Po prvním pohledu na graf se teď vyplatí pojmenovat, co jsme vlastně zobrazili. Pracujeme se dvěma numerickými proměnnými:

- **osa x:** délka ploutve v milimetrech (`flipper_length_mm`)
- **osa y:** tělesná hmotnost v gramech (`body_mass_g`)
- doplňkově kategoriální proměnná druh tučňáka (`species`)

Přiřazení os je při popisu korelace libovolné. Kdybychom osy prohodili — délku svisle a hmotnost vodorovně — bodový mrak by vypadal jinak, ale síla vztahu by zůstala naprosto stejná. Pojmy *prediktor* a *odezva*, které popisují asymetrii os (jedna proměnná „vysvětluje“ druhou), patří k regresním modelům; ty si ukážeme v pozdějších lekcích.



Obrázek 3: Stejná data, dvě orientace os. Tvar mraku bodů se změní, ale síla vztahu zůstane identická.

Bodový graf nám umožňuje podívat se současně na směr vztahu i na to, jak moc jsou hodnoty rozptýlené kolem hlavního vzoru.

Když ale sledujeme vztah dvou proměnných obecněji, typ grafu vybíráme podle toho, jaké proměnné máme k dispozici:


Dvojice proměnných	Co chceme na první pohled vidět	Dobrá první volba
dvě numerické proměnné	směr vztahu a rozptyl bodů	bodový graf
kategoriální + numerická proměnná	rozdíly mezi skupinami a překryv rozdělení	boxplot, případně body ve skupinách
dvě kategoriální proměnné	kolik pozorování spadá do jednotlivých kombinací	tabulka četností nebo sloupcový graf

Obecné pravidlo tedy nezní jen „je v datech nějaký vztah?“, ale také „jaký graf vůbec dává pro tuto dvojici proměnných smysl?“ V této chvíli ale zůstaneme u první řádky tabulky a budeme dál číst jeden bodový graf dvou numerických proměnných.

7 Rozptyl ve dvou směrech

U jednorozměrných dat sledujeme rozptyl jen v jednom směru, například jak moc se hodnoty hmotnosti liší kolem průměru. V bodovém grafu ale kolísají obě osy současně. Jeden tučňák může mít o něco delší ploutev než jiný a zároveň se může lišit i hmotností. Výsledkem je mrak bodů, který má šířku i výšku.

Na obrázku níže je stejný vztah zobrazený dvakrát. Vlevo si všímáme, že i při podobné délce ploutve mohou mít jedinci docela odlišnou hmotnost. Vpravo naopak vidíme, že i při podobné hmotnosti se může měnit délka ploutve.



Obrázek 4: Stejný bodový graf můžeme číst ve dvou směrech: při podobné délce ploutve se může lišit hmotnost a při podobné hmotnosti se může lišit délka ploutve. Zvýrazněné body leží uvnitř příslušného pásu.

To je důležité pro interpretaci. Když vidíme podlouhlý oblak bodů směřující zleva dole doprava nahoru, znamená to, že vedle celkového trendu stále existuje velký lokální rozptyl. Dva jedinci s téměř stejnou délkou ploutve nemusí mít stejnou hmotnost a dva podobně těžcí jedinci nemusí mít stejně dlouhou ploutev.

Abychom rozptyl jedné proměnné vyjádřili přesně číslem, zavedeme jeho přesnou definici a z ní odvozenou směrodatnou odchylku. Jako příklad použijeme malý vzorek 4 tučňáků druhu Adélie (průměr délky ploutve: 188,8 mm). Tabulka ukazuje délku ploutve každého z nich, odchylku od průměru a čtverec té odchylky:

Tučňák	Délka ploutve (mm)	Odchylka od průměru (188,8 mm)	Čtverec odchylky (mm ²)
1	181	-7.8	60.1
2	186	-2.8	7.6
3	190	1.2	1.6

Tuč- ňák	Délka ploutve (mm)	Odchylka od průměru (188,8 mm)	Čtverec odchylky (mm ²)
4	198	9.2	85.6

$$\begin{aligned}
 s_x^2 &= \frac{(181 - 188,8)^2 + (186 - 188,8)^2 + (190 - 188,8)^2 + (198 - 188,8)^2}{4 - 1} \\
 &= \frac{60,1 + 7,6 + 1,6 + 85,6}{3} \\
 &= \frac{154,8}{3} = 51,6 \text{ mm}^2
 \end{aligned}$$

Pro libovolný soubor n pozorování platí obecný zápis:

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_x = \sqrt{s_x^2}$$

V celém souboru tučňáků vychází směrodatná odchylka délky ploutve přibližně 14.1 mm a tělesné hmotnosti přibližně 802 g. Tato čísla říkají, o kolik milimetrů nebo gramů se typický jedinec odchyluje od průměru celého souboru. V dalším kroku tuto myšlenku rozšíříme na dvě proměnné zároveň.

8 Proč jsou data rozptýlená

Variabilita v biologických datech není chyba, kterou bychom měli odstranit. Je to vlastnost reálného světa. Dva tučňáci mohou mít podobně dlouhou ploutev, ale lišit se druhem, pohlavím, věkem nebo celkovou tělesnou stavbou. K rozptylu přispívá i běžná nepřesnost měření a to, že žádný biologický vztah nebývá dokonale přesný.

Na tomto místě je užitečné rozlišit několik zdrojů rozptylu, které se v grafu míchají dohromady:

- **biologické rozdíly mezi jedinci:** dva podobní jedinci nemusí být stejně těžcí ani stejně stavění
- **rozdíly mezi skupinami:** část variability vzniká tím, že v jednom grafu spojujeme více druhů
- **nepřesnost a omezení měření:** reálná data nikdy nejsou úplně bez chyby
- **další nevysvětlené vlivy:** sledujeme jen malou část toho, co hmotnost organismu ovlivňuje

V našem datasetu se délka ploutve pohybuje přibližně od 172 do 231 mm a tělesná hmotnost od 2700 do 6300 g. Už z tohoto rozsahu je vidět, že nejde o několik téměř stejných jedinců, ale o biologicky pestrý soubor měření.

9 Kovariance: jak se dvě proměnné pohybují společně

Rozptyl jedné proměnné popisuje, jak moc jsou její hodnoty rozptýleny kolem průměru. Jakmile ale sledujeme dvě proměnné zároveň, zajímá nás, zda se jejich odchylky od průměru pohybují *společně*. Když jedinci s nadprůměrně dlouhou ploutví mají také nadprůměrnou hmotnost, jejich odchylky od průměru mají stejné znaménko a součin je kladný. Právě to zachycuje kovariance.

Pro stejný malý vzorek 4 tučňáků Adelie tabulka ukazuje odchylky obou proměnných od jejich průměrů a součin každé dvojice odchylek:

Tuč- ňák	Odch. délky (mm), prům. 188,8 mm	Odch. hmotnosti (g), prům. 4050 g	Součin odchylek (mm·g)
1	-7.8	-300	2325
2	-2.8	-250	688
3	1.2	200	250
4	9.2	350	3238


$$\begin{aligned}
 \text{cov}(x, y) &= \frac{(-7,8) \cdot (-300) + (-2,8) \cdot (-250) + (1,2) \cdot (200) + (9,2) \cdot (350)}{4 - 1} \\
 &= \frac{2325 + 688 + 250 + 3238}{3} \\
 &= \frac{6500}{3} = 2167 \text{ mm} \cdot \text{g}
 \end{aligned}$$

Pro n pozorování obecně:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Intuici si usnadníme grafem. Přidáme do bodového grafu dvě přerušované čáry – vertikální ve výši průměrné délky ploutve (200.9 mm) a horizontální ve výši průměrné hmotnosti (4202 g). Vzniknou čtyři kvadranty, z nichž každý přispívá ke kovarianci jinak:

- **vpravo nahoře** ($x > \bar{x}, y > \bar{y}$): obě odchylky kladné – příspěvek kladný
- **vlevo dole** ($x < \bar{x}, y < \bar{y}$): obě odchylky záporné – součin je stále kladný $(-) \cdot (-) = (+)$
- **vpravo dole** ($x > \bar{x}, y < \bar{y}$): odchylky s opačnými znaménky – příspěvek záporný
- **vlevo nahoře** ($x < \bar{x}, y > \bar{y}$): odchylky s opačnými znaménky – příspěvek záporný



Obrázek 5: Bodový graf tučňáků s průměrnými čarami (přerušovaně). Oranžové kvadranty přispívají ke kovarianci kladně, fialové záporně.

🔍 Přečtěte si obrázek

Podívejte se na obrázek: ve kterých kvadrantech se shlukuje nejvíce bodů? Co to říká o tom, jakým směrem se délka ploutve a hmotnost pohybují spolu?

💡 Odpověď

Oranžové kvadranty (vpravo nahoře a vlevo dole) převažují — jedinci s nadprůměrně dlouhou ploutví mají zpravidla i nadprůměrnou hmotnost, a naopak. Kovariance proto bude kladná.

Oranžové kvadranty převažují — jedinci s delší ploutví mají zpravidla i větší hmotnost, a naopak. Kovariance proto vychází kladná: přibližně 9824 mm·g.

Kovariance ale závisí na jednotkách. Kdybychom přepočítali délku z milimetrů na centimetry, kovariance by se stokrát zmenšila. Abychom vztah popsali číslem nezávislým na jednotkách, musíme ji ještě přepočítat pomocí směrodatných odchylek obou proměnných. Nejdřív si to ukážeme na stejném malém vzorku a teprve potom zapíšeme obecný vzorec.

Na stejném malém vzorku 4 tučňáků si můžeme ukázat i plný výpočet Pearsonova r . Potřebujeme pro něj stejnou informaci jako před chvílí u kovariance, ale navíc i čtverce odchylek obou proměnných:

Tuč- ňák	Odch. délky (mm)	Odch. hmotno- sti (g)	Součin od- chylek	Čtverec odch. délky	Čtverec odch. hmotnosti
1	-7.8	-300	2325	60.1	90000
2	-2.8	-250	688	7.6	62500

Tuč- ňák	Odch. délky (mm)	Odch. hmotno- sti (g)	Součin od- chylek	Čtverec odch. délky	Čtverec odch. hmotnosti
3	1.2	200	250	1.6	40000
4	9.2	350	3238	85.6	122500

$$\begin{aligned}
 r &= \frac{(-7, 8) \cdot (-300) + (-2, 8) \cdot (-250) + (1, 2) \cdot (200) + (9, 2) \cdot (350)}{\sqrt{[(-7, 8)^2 + (-2, 8)^2 + (1, 2)^2 + (9, 2)^2][(-300)^2 + (-250)^2 + (200)^2 + (350)^2]}} \\
 &= \frac{2325 + 688 + 250 + 3238}{\sqrt{(60, 1 + 7, 6 + 1, 6 + 85, 6) \cdot (90000 + 62500 + 40000 + 122500)}} \\
 &= \frac{6500}{\sqrt{154, 8 \cdot 315000}} = 0, 93
 \end{aligned}$$

Tímto normalizováním dostaneme Pearsonův korelační koeficient, který leží vždy v intervalu $[-1, +1]$. V našich datech vychází přibližně 0,87 – přesně stejný výsledek jako přímý výpočet (0,87), jen odvozený jinou cestou.

Obecně tedy můžeme Pearsonovu korelaci zapsat i bez jednotek takto:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

10 Korelace jako stručný číselný popis

Graf je vždy první krok, ale někdy chceme vztah dvou numerických proměnných shrnout i číslem. K tomu slouží korelace. V datech tučňáků vychází Pearsonova korelace přibližně 0,87 a Spearmanova korelace přibližně 0,84. Pearsonovo r jsme před chvílí odvodili z kovariance – vydělíme kovarianci součinem směrodatných odchylek a dostaneme číslo v rozsahu $[-1, +1]$.

V R si obě čísla spočítáme přímo nad stejnými dvěma sloupci, které jsme předtím použili pro bodový graf:

```
cor(
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
  method = "pearson"
)
```

```
[1] 0.8712018
```

```
cor(
  x = data_tucnaci$delka_ploutve_mm,
```

```


y = data_tucnaci$hmotnost_g,
method = "spearman"
)

```

```
[1] 0.8399741
```

Takto dostaneme dvě stručná čísla, která shrnují tutéž biologickou otázku trochu jiným způsobem: Pearson zdůrazňuje lineární vztah, Spearman pořadí hodnot.

Na schématu níže jsou čtyři typické situace. Všimněte si, jak se tvar bodového mraku mění a jak na různé hodnoty r reagují Pearson (P) a Spearman (S) odlišně.



Obrázek 6: Čtyři typické situace korelace: silná kladná lineární, žádná korelace, silná záporná lineární a monotónní, ale zakřivený vztah. U každého panelu jsou hodnoty Pearsonovy (P) a Spearmanovy (S) korelace.

Pearson	Spearman
pracuje s původními hodnotami	pracuje s pořadím hodnot
shrnuje hlavně lineární vztah	shrnuje monotónní vztah
bývá citlivější na odlehlé body	bývá vůči odlehlým bodům odolnější

Pearsonova korelace shrnuje, jak silně spolu souvisejí hodnoty na obou osách v lineárním smyslu. Spearmanova korelace pracuje s pořadím hodnot, takže je vhodná jako neparametrická alternativa tam, kde nás zajímá spíš monotónní vztah než přesně lineární průběh. Bývá také méně citlivá na odlehlé body.

Když body tvoří přibližně rostoucí oblak bez výrazně zvláštních bodů, bývají obě korelace podobné. Pokud by byl vztah zakřivený nebo by několik bodů silně vyčnívalo, mohl by být rozdíl mezi Pearsonem a Spearmanem už informativní sám o sobě.

V této lekci je důležité hlavně to, že obě čísla mají podpůrnou roli. Nenahrazují graf ani biologickou interpretaci. Pomáhají jen stručně vyjádřit, že delší ploutve bývají spojeny s vyšší hmotností a že tento vztah je v datech zřetelný i po převodu do číselné podoby.

11 Korelace není kauzalita

V této chvíli už umíme vztah dvou číselných proměnných dobře popsat slovně i číslem. Je ale důležité nepřekročit hranici toho, co nám korelace opravdu říká. Korelace popisuje, že se dvě proměnné mění společně, ale sama o sobě ještě neukazuje, která proměnná je příčinou druhé.

U tučňáků tedy můžeme bezpečně říct, že delší ploutev bývá spojena s vyšší hmotností. Nemůžeme ale jen z korelace uzavřít, že změna délky ploutve přímo způsobuje změnu hmotnosti. Část vztahu může vznikat i tím, že obě proměnné souvisejí s celkovou velikostí těla nebo s druhem.

To je důvod, proč po vizualizaci a korelaci obvykle následuje modelování. Až model nám pomáhá oddělit, co je společný vzor v datech, co je efekt konkrétní proměnné a jak velká je nejistota kolem tohoto odhadu.

! Co je správná interpretace?

- **A:** Kladná korelace znamená, že jsme prokázali příčinný vztah.
- **B:** Kladná korelace znamená, že proměnné spolu souvisejí, ale příčinu musíme řešit opatrněji.
- **C:** Korelace je jen technické číslo bez biologického významu.


i Odpověď

Správně je **B**. Korelace je biologicky užitečný souhrn společného vzoru v datech, ale sama ještě nerozlišuje přímou příčinu od dalších možných vysvětlení.

12 Stejný graf, ale s viditelnými druhy

Teď se můžeme vrátit ke stejnému bodovému grafu a odkrýt ještě jednu informaci: druh tučňáka. Původní šedý oblak bodů se rozpadne na několik podskupin, které se částečně překrývají, ale zároveň mají vlastní polohu a vlastní rozptyl.

To je důležité didakticky i biologicky. V původním bodovém grafu jsme viděli „jeden“ vztah, ale část tohoto vztahu je tvořena tím, že různé druhy mají různé typické kombinace délky ploutve a hmotnosti. Jinými slovy: část rozptylu není jen náhodný šum, ale odráží i skutečnou strukturu dat.



Jakmile jsou druhy vidět, je snazší pochopit, proč byl původní rozptyl tak široký. Část variability vzniká uvnitř druhů, ale část je dána i tím, že v jednom obrázku mícháme více biologicky odlišných skupin. To je přesně okamžik, kdy nám doplňková kategoriální proměnná pomůže lépe číst vztah dvou číselných proměnných.

13 Jak typ proměnných určuje výběr grafu


Typ grafu nevybíráme podle toho, co je „hezčí“, ale podle toho, jaký vztah mezi proměnnými chceme přechít. Jinak čteme dvě číselné osy, jinak porovnáváme skupiny proti číslům a jinak sledujeme složení dvou kategoriálních proměnných.

Jako rychlá pomůcka pomáhají dvě otázky:

- Jsou obě proměnné číselné?
- Nebo jedna z nich hlavně rozděluje pozorování do skupin?

13.1 Dvě numerické proměnné: délka ploutve a hmotnost

Právě proto jsme v této lekci začali bodovým grafem. Když jsou obě proměnné numerické, bývá bodový graf nejlepší první volbou: každý bod nese dvojici hodnot a my můžeme najednou číst směr vztahu, sílu rozptylu, možné shluky i odlehlé body.




Obrázek 7: Dvě numerické proměnné: bodový graf je přirozený první krok, protože každý bod nese dvojici hodnot současně.

U tučňáků jsme v něm viděli, že delší ploutve bývají spojené s vyšší hmotností, ale také že vztah není dokonale těsný. Právě to je důvod, proč bodový graf nepřeskakovat. Žádné jediné číslo nám neukáže tvar oblaku bodů tak přímo.

Když ale chceme ve stejných datech zvýraznit jinou vlastnost vztahu, můžeme použít i několik dalších variant. Každá z nich ukazuje něco trochu jiného.


13.1.a Hladký trend

Čára pomáhá rychle přecíst hlavní směr vztahu, ale body pořád zůstávají viditelné.




13.1.b Hustota v mřížce

Když je bodů hodně, můžeme místo jednotlivých bodů ukázat, kde se měření hromadí nejvíce.




13.1.c Po druzích

Rozdělení do panelů pomáhá odlišit, co je společný trend a co je rozdíl mezi skupinami.



13.2 KATEGORIÁLNÍ A NUMERICKÁ PROMĚNNÁ: DRUH A HMOTNOST

Jakmile nás začne zajímat přímo vztah mezi druhem a tělesnou hmotností, bodový graf už není nejprůběžnější první volbou. Teď totiž nesrovnáváme dvě číselné osy, ale kategoriální proměnnou určující skupiny a numerickou proměnnou, která se mezi nimi porovnává.



Než si přečtete vysvětlení, zkuste si v grafu najít tři věci:

- Který druh leží typicky nejvýš?
- Kde se rozdělení hmotnosti mezi druhy překrývá a kde už méně?
- Je rozptyl uvnitř jednotlivých druhů malý, nebo i v rámci jednoho druhu zůstává docela velký?

i Odpověď

Tučňáci druhu Gentoo leží typicky nejvýš. Adelie a Chinstrap se vzájemně překrývají více. I uvnitř každého druhu je viditelný rozptyl – takže ani znalost druhu sama o sobě nestačí k přesnému odhadu hmotnosti konkrétního jedince.


Na tomto grafu nečteme směr vztahu jako v bodovém grafu. Místo toho sledujeme, zda se rozdělení tělesné hmotnosti mezi druhy překrývá, nebo zda některé skupiny leží typicky výš či níž. I to je vztah dvou proměnných: hodnota jedné proměnné se mění podle úrovně druhé.

Na první pohled se zdá, že tučňáci druhu Gentoo leží typicky výš než Adelie a Chinstrap. Zároveň ale skupiny nejsou úplně oddělené a i uvnitř každého druhu zůstává viditelný rozptyl. Pro tuto kombinaci typů proměnných je proto často přirozenější boxplot nebo body rozdělené do skupin než klasický bodový graf.

Totéž srovnání ale můžeme nakreslit i jinak podle toho, zda chceme zdůraznit jednotlivé body, šířku skupin nebo jen jejich shrnutí.


13.2.a Samotné body

Nejlépe ukazují jednotlivá měření a překryv skupin, ale hůře shrnují jejich střed.




13.2.b Krabice bez bodů

Rychle shrnou polohu a překryv skupin, ale skryjí jemnější tvar rozložení uvnitř každého druhu.



13.2.c Šířka rozložení

Hladký obrys dává lepší představu o tom, kde je v každé skupině více a méně hodnot.



Další užitečný případ jsou dvě kategoriální proměnné najednou.

13.3 Druh a kategorie délky ploutve

Jinou situaci dostaneme, když obě proměnné rozdělují data do skupin. Abychom si to ukázali na stejných datech, rozdělíme délku ploutve do tří seřazených kategorií: kratší, střední a delší. Je to jen didaktická ukázka kombinace typů proměnných, ne doporučený první analytický krok pro spojitou proměnnou. Teď už nechceme číst přesné číselné hodnoty na ose y, ale složení skupin podle podílů.



U takového grafu nás zajímá něco jiného než u boxplotu. Neptáme se, jaká je typická hodnota, ale jaké je zastoupení druhů uvnitř jednotlivých kategorií délky ploutve. Proto se zde velmi hodí proporční sloupcový graf: každá skupina má stejnou výšku 100 % a my snadno porovnáváme podíly.

Než si přečtete vysvětlení, zkuste odhadnout:

- Ve které kategorii délky ploutve má druh Gentoo největší podíl?
- Kde naopak převažuje Adelie?
- Vypadá kategorie středních ploutví druhově smíšeněji než krajní kategorie?


i Odpověď

Gentoo má nejvyšší podíl mezi delšími ploutvemi, zatímco Adelie převažuje mezi kratšími ploutvemi. Střední kategorie bývá druhově smíšenější. Právě tuto změnu ve složení skupin proporční sloupčový graf ukazuje velmi přehledně.

Stejná dvojice kategoriálních proměnných se ale dá zobrazit i jinými způsoby podle toho, zda chceme zdůraznit podíly, absolutní počty nebo přehled celé tabulky najednou.


13.3.a Proporce

Když mají mít všechny sloupce stejnou výšku, snadno porovnáváme složení kategorií mezi sebou.




13.3.b Absolutní počty

Vedle sebe postavené sloupce se hodí tehdy, když nás zajímá i velikost jednotlivých skupin, nejen jejich složení.



13.3.c Tepelná mapa


Když chceme rychle přehledně celou tabulku kombinací, je praktické převést ji na barevnou mřížku.



13.3.d Dlaždicový graf

Každý čtvereček představuje 1 % dané kategorie. Tento typ grafu se hodí tehdy, když chceme podíly ukázat ještě doslova a po malých dílcích.


Dlaždicový graf: 100 dílků pro každou kategorii délky ploutve



Ještě jiný případ je seřazená osa proti numerické proměnné.

13.4 Seřazené kategorie délky ploutve a hmotnost

Stejně vytvořené kategorie můžeme použít ještě jinak: jako ordinální proměnnou na ose x a hmotnost jako numerickou proměnnou na ose y. V takové chvíli je užitečný opět boxplot, ale tentokrát je zásadní, že pořadí kategorií na ose nese informaci.



Než si přečtete vysvětlení, zkuste si všimnout tří věcí:


- Posouvá se typická hmotnost od kratších ploutví k delším?
- Kde se skupiny ještě překrývají a kde už méně?
- Co by se ztratilo, kdybychom pořadí kategorií na ose x promíchali?

Tentokrát neporovnáváme nepojmenované skupiny, ale seřazené stupně. Proto má smysl sledovat, zda se s rostoucí kategorií posouvá i typická hmotnost. Kdybychom pořadí kategorií na ose promíchali, velká část sdělení grafu by se ztratila.

I zde ale existuje více rozumných variant. Některé lépe ukazují jednotlivá pozorování, jiné zase co nejstručnější souhrn podle pořadí.


13.4.a Samotné body

Když chceme ponechat všechna měření viditelná, stačí je rozložit do stran v jednotlivých kategoriích.




13.4.b Spojené středy

Pokud chceme co nejrychleji číst posun od kratších k delším kategoriím, pomůže jednoduché spojení typických hodnot.



13.4.c Šířka rozložení

Hladký obrys pomůže ukázat, kde jsou v každé seřazené skupině data koncentrovaná a kde naopak řidká.



i Poznámka k tomuto příkladu

Kategorie kratší, střední a delší jsme zde vytvořili uměle z číselné proměnné jen proto, abychom si ukázali práci s ordinální proměnnou. Stejný typ grafu bychom ale použili i pro přirozeně seřazené biologické škály, například malý–střední–velký nebo nízký–střední–vysoký.

13.5 Rychlá tabulka: který graf zvolit jako první?

Typ proměnných	Co chceme zobrazit	Dobrý první graf	Co v něm hledat
jedna numerická	Jak vypadá rozdělení jedné číselné proměnné	histogram	tvar rozdělení, rozptyl, odlehlé body
jedna kategoriální	Kolik pozorování padá do jednotlivých skupin	sloupcový graf	četnosti, podíly, nerovnováha skupin
numerická + numerická	Jak spolu souvisejí dvě číselné proměnné	bodový graf	směr vztahu, tvar oblaku bodů, shluky, odlehlé body
kategoriální + numerická	Jak se liší číselná proměnná mezi skupinami	boxplot + body	typická hodnota, překryv skupin, vnitroskupinový rozptyl
kategoriální + kategoriální	Jak se mezi skupinami mění složení kategorií	skládaný sloupcový graf s proporci	rozdíly v podílech mezi skupinami

Typ měnných	pro-	Co chceme zobrazit	Dobrý první graf	Co v něm hledat
ordinální numerická	+	Jak se mění číselná měnná napříč seřazenými stupni	boxplot se seřaze- nou osou	posun mediánu, překryv, monotónní trend

Tahle tabulka není seznam všech možných grafů. Je to bezpečný první krok pro situaci, kdy si nejdřív potřebujeme ujasnit, co vlastně porovnáváme. Až potom má smysl přidávat další vrstvy, jemnější styl nebo formálnější model.

14 Co zatím ještě nemůžeme tvrdit

! Která formulace je v této chvíli správně?

- **A:** V grafu je vidět vztah, takže jsme prokázali efekt.
- **B:** V datech je vidět biologicky smysluplný vzor, který chceme popsat přesněji.
- **C:** Protože body neleží na jedné přímce, mezi proměnnými žádný vztah není.

i Odpověď

Nejllepší odpověď je **B**. Graf ukazuje vzor, ale nestačí k prokázání efektu — k tomu potřebujeme model, odhad velikosti vztahu a kvantifikaci nejistoty.


Častý omyl zní: v grafu je vidět vztah, takže jsme prokázali efekt. To je předčasné závěr. Z grafu zatím víme, že data vypadají zajímavě a že stojí za další analýzu. Nevíme ještě, jak přesně vztah popsat, jak je silný a jak velká je nejistota kolem našeho odhadu.

Správná formulace pro tuto chvíli je skromnější: v datech vidíme vzor, který je biologicky smysluplný a který chceme v dalších lekcích popsat přesněji.

15 Co bude následovat dál

V další lekci navážeme lineárním modelem, který nám pomůže převést viditelný vzor do číselné podoby. Teprve potom bude dávat smysl mluvit o tom, jak velký vztah mezi proměnnými je a jak moc mu věříme.

Palmer Penguins ale nabízí i další proměnné, které se budou hodit pro pozdější příklady, například délku a hloubku zobáku. Stejná logika výběru grafu a interpretace vztahu se pak bude dát použít i na jiné biologické otázky než jen na délku ploutve a hmotnost.



Obrázek 8: Schéma měření délky a hloubky zobáku v datech Palmer Penguins. Ilustrace: Allison Horst.

16 Shrnutí

- Nejprve se vyplatí dobře přechíst jeden bodový graf dvou numerických proměnných a teprve potom přidávat další vrstvy informace.
- V bodovém grafu sledujeme rozptyl ve dvou směrech současně, ne jen odchylku kolem jediné hodnoty.
- Korelace je stručný číselný popis vztahu dvou numerických proměnných, ale sama o sobě nenahrazuje graf ani interpretaci.
- Doplnková kategoriální proměnná může odhalit, že část původního rozptylu souvisí se skutečnou strukturou dat.
- Typ grafu vybíráme podle dvojice proměnných: pro numerická data často bodový graf, pro kategoriální a numerickou proměnnou často boxplot nebo body rozdělené do skupin.
- V grafu můžeme rozpoznat směr vztahu, ale ještě tím neprokazujeme efekt.
- L02 připravuje půdu pro další krok: přesnější popis vztahu a nejistoty pomocí modelu.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice:

```
data frame with 0 columns and 0 rows
```