

Vztahy dvou proměnných a vizualizace

Podkladové čtenářské materiály k přednášce

25. července 2026

Obsah

1 Úvod	2
2 Co si z této lekce odnést	2
3 Jaká data budeme používat	3
4 První graf: délka ploutve a tělesná hmotnost	3
5 Co v grafu vidíme	5
6 Jaké proměnné budeme sledovat	6
7 Rozptýl ve dvou směrech	7
8 Proč jsou data rozptýlená	8
9 Kovariance: jak se dvě proměnné pohybují společně	9
10 Korelace jako stručný číselný popis	12
11 Korelace není kauzalita	13
12 Stejný graf, ale s viditelnými druhy	14
13 Jak typ proměnných určuje výběr grafu	15
13.1 Dvě numerické proměnné: délka ploutve a hmotnost	15
13.1.a Hladký trend (<i>fitted trend line</i>)	15
13.1.b Hustota v mřížce (<i>2D histogram</i>)	16
13.1.c Po druzích v panelech (<i>small multiples</i>)	16
13.2 Kategoriální a numerická proměnná: druh a hmotnost	17
13.2.a Samotné body (<i>beeswarm plot</i>)	18
13.2.b Krabice bez bodů (<i>box plot</i>)	18
13.2.c Šířka rozložení (<i>violin plot</i>)	19
13.3 Druh a kategorie délky ploutve	19
13.3.a Proporce (<i>proportional stacked bar chart</i>)	20
13.3.b Absolutní počty (<i>grouped bar chart</i>)	21
13.3.c Tepelná mapa (<i>heat map</i>)	21
13.3.d Dlaždicový graf (<i>waffle chart</i>)	22
13.4 Seřazené kategorie délky ploutve a hmotnost	22
13.4.a Samotné body (<i>beeswarm plot</i>)	23
13.4.b Spojené středy (<i>line plot of group summaries</i>)	24
13.4.c Šířka rozložení (<i>violin plot</i>)	24
13.5 Rychlá tabulka: který graf zvolit jako první?	25
14 Co zatím ještě nemůžeme tvrdit	25

15 Co bude následovat dál	26
16 Shrnutí	26
Slovníček pojmů	27

1 Úvod

V minulé lekci jsme se naučili nejprve určit, co představuje jeden řádek, rozpoznat typ jedné proměnné a zvolit pro ni poctivý souhrn a graf. Teď položíme druhou proměnnou vedle první. Stejná pravidla stále platí, ale otázka se mění: nehledáme už jen tvar jednoho rozdělení, nýbrž vztah mezi dvěma znaky.

U živočichů často čekáme, že větší tělo bude souviset s většími orgány nebo končetinami. U tučňáků si proto můžeme položit jednoduchou otázku: mají jedinci s delší ploutví také větší tělesnou hmotnost? Tato otázka je vhodná pro první krok do světa vztahů dvou proměnných, protože nás nutí přemýšlet nejen o tvaru vzoru, ale i o variabilitě dat.

💡 Otázka před prvním grafem

Co byste čekali ještě před tím, než se podíváme na data?

- Delší ploutev téměř vždy znamená vyšší hmotnost.
- Delší ploutev bude s vyšší hmotností souviset, ale ne dokonale.
- Délka ploutve a hmotnost spolu souviset nebudou.

Než budete číst dál, zkuste si vybrat, která odpověď vám připadá nejpravděpodobnější, a proč.

i Odpověď

Biologicky nejpravděpodobnější je **možnost B**: délka ploutve bude s tělesnou hmotností souviset, ale ne dokonale. Tělesné rozměry tučňáků jsou vzájemně provázány, ale každý jedinec je jiný — liší se druhem, pohlavím, věkem i podmínkami prostředí. Dokonalá shoda by v reálných biologických datech byla překvapivá.


2 Co si z této lekce odnést

- vybrat vhodný graf pro vztah dvou proměnných
- popsát, jaký vzor v datech vidíme a co zatím říct nemůžeme
- vysvětlit, proč jsou reálná biologická data rozptýlená i tehdy, když v nich pozorujeme zřetelný směr
- stručně popsát vztah dvou numerických proměnných pomocí korelace a vysvětlit, proč se Pearson a Spearman mohou lišit
- připravit si půdu pro další lekce, kde budeme vztah dvou proměnných popisovat modelem

3 Jaká data budeme používat

Budeme pracovat s datasety Palmer Penguins, které shrnují měření tučňáků z oblasti Palmer Station v Antarktidě. Pro tuto lekci jsme ponechali 342 pozorování, u nichž známe délku ploutve, tělesnou hmotnost a druh. V datech se objevují 3 druhy: Adelie, Chinstrap, Gentoo.

Na tomto datasetu je užitečné to, že biologický příběh dává smysl i bez složité statistiky. Delší ploutev může souviset s větší tělesnou velikostí, ale zároveň víme, že do výsledku vstupují i další zdroje rozdílů mezi jedinci.




Obrázek 1: Druhy tučňáků v datasetu Palmer Penguins. Ilustrace: Allison Horst.

Na obrázku výše jsou 3 druhy, se kterými budeme pracovat. Už z ilustrace je vidět, že se mezi nimi mohou lišit tělesné proporce. To je dobrá připomínka, že část rozptylu v bodovém grafu může souviset i s tím, že nesledujeme jediný homogenní typ jedince.

Jako první krok se ale na data podíváme co nejjednodušším způsobem: bez rozlišování druhů, jen jako na vztah mezi délkou ploutve a tělesnou hmotností.

4 První graf: délka ploutve a tělesná hmotnost

Nejprve si zobrazíme co nejjednodušší bodový graf. V tuto chvíli nechceme nic testovat ani odhadovat pomocí modelu. Chceme si všimnout, jak data vypadají.



Obrázek 2: Bodový graf délky ploutve (mm) a tělesné hmotnosti (g) v datasetu Palmer Penguins.

Tento první graf obsahuje 342 tučňáků a ukazuje stejná data, která si studenti později vyzkoušejí číst i pomocí modelu.

Než si podobný graf nakreslíme sami, je užitečné v R rychle zkontrolovat prvních několik hodnot na obou osách:

```
head(
  # Prvních šest délek ploutve – hodnoty na ose x
  x = data_tucnaci$delka_ploutve_mm
)
```

```
[1] 181 186 195 193 190 181
```


```
head(
  # Prvních šest hmotností – hodnoty na ose y
  x = data_tucnaci$hmotnost_g
)
```

```
[1] 3750 3800 3250 3450 3650 3625
```

Jakmile víme, které dvě proměnné chceme porovnat, můžeme tentýž první bodový graf rychle nakreslit v základním R:

```
plot(
  # Každý řádek dat vytvoří jeden bod se dvěma souřadnicemi
  x = data_tucnaci$delka_ploutve_mm,
  y = data_tucnaci$hmotnost_g,
```

```
# Popisky připomínají význam a jednotky obou os
xlab = "Délka ploutve (mm)",
ylab = "Tělesná hmotnost (g)",
# Plné, průhledné body omezí překrývání
pch = 16,
col = rgb(red = 0.54, green = 0.54, blue = 0.54, alpha = 0.6)
)
```



5 Co v grafu vidíme

Na první pohled je vidět rostoucí mrak bodů: tučňáci s delší ploutví bývají častěji těžší. To je důležitý první poznatek. Zároveň ale body neleží na jedné přímce. I při podobné délce ploutve se může tělesná hmotnost lišit o stovky gramů.

Před dalším čtením se zkuste zastavit u tří krátkých otázek:

- Kde je vztah mezi proměnnými nejsnadněji viditelný?
- Jak velký je rozptyl kolem hlavního směru?
- Vidíte body, které se od většiny ostatních odlišují?

i Odpověď

Celkový směr vztahu je zřetelně rostoucí: tučňáci s delší ploutví bývají těžší. Kolem tohoto trendu ale zůstává dost široký oblak bodů. Vztah v datech vidíme, ale není natolik jednoduchý, aby se dal popsat jedinou čarou bez dalších otázek.


Základní odpověď je tato: celkový směr vztahu je zřetelně rostoucí, ale kolem něj zůstává dost široký oblak bodů. Už teď tedy víme dvě důležité věci zároveň: vztah v datech opravdu vidíme, ale není natolik jednoduchý, aby se dal popsat jedinou „čistou“ čarou bez dalších otázek.

6 Jaké proměnné budeme sledovat

Po prvním pohledu na graf se teď vyplatí pojmenovat, co jsme vlastně zobrazili. Pracujeme se dvěma numerickými proměnnými:

- **osa x:** délka ploutve (anglicky *flipper length*) v milimetrech (`flipper_length_mm`)
- **osa y:** tělesná hmotnost (anglicky *body mass*) v gramech (`body_mass_g`)
- doplňkově kategoriální proměnná druh tučňáka (anglicky *species*; `species`)

Přiřazení os je při popisu korelace libovolné. Kdybychom osy prohodili — délku svisle a hmotnost vodorovně — bodový mrak by vypadal jinak, ale síla vztahu by zůstala naprosto stejná. Pojmy *prediktor* a *odezva*, které popisují asymetrii os (jedna proměnná „vysvětluje“ druhou), patří k regresním modelům; ty si ukážeme v pozdějších lekcích.



Obrázek 3: Stejná data, dvě orientace os. Tvar mraku bodů se změní, ale síla vztahu zůstane identická.

Bodový graf nám umožňuje podívat se současně na směr vztahu i na to, jak moc jsou hodnoty rozptýlené kolem hlavního vzoru.

Když ale sledujeme vztah dvou proměnných obecněji, typ grafu vybíráme podle toho, jaké proměnné máme k dispozici:


- **Dvě numerické proměnné:** hledáme směr vztahu a rozptyl bodů. Dobrou první volbou je bodový graf (anglicky *scatter plot*).
- **Kategoriální a numerická proměnná:** hledáme rozdíly mezi skupinami a překryv rozdělení. Dobrou první volbou je krabicový graf (anglicky *box plot*), případně body rozdělené do skupin.
- **Dvě kategoriální proměnné:** sledujeme, kolik pozorování spadá do jednotlivých kombinací. Začít můžeme tabulkou četností nebo sloupcovým grafem (anglicky *bar chart*).

Obecné pravidlo tedy nezní jen „je v datech nějaký vztah?“, ale také „jaký graf vůbec dává pro tuto dvojici proměnných smysl?“ V této chvíli ale zůstaneme u první řádky tabulky a budeme dál číst jeden bodový graf dvou numerických proměnných.

7 Rozptyl ve dvou směrech

U jednorozměrných dat sledujeme rozptyl jen v jednom směru, například jak moc se hodnoty hmotnosti liší kolem průměru. V bodovém grafu ale kolísají obě osy současně. Jeden tučňák může mít o něco delší ploutev než jiný a zároveň se může lišit i hmotností. Výsledkem je mrak bodů, který má šířku i výšku.

Na obrázku níže je stejný vztah zobrazený dvakrát. Vlevo si všímáme, že i při podobné délce ploutve mohou mít jedinci docela odlišnou hmotnost. Vpravo naopak vidíme, že i při podobné hmotnosti se může měnit délka ploutve.



Obrázek 4: Stejný bodový graf můžeme číst ve dvou směrech: při podobné délce ploutve se může lišit hmotnost a při podobné hmotnosti se může lišit délka ploutve. Zvýrazněné body leží uvnitř příslušného pásu.

To je důležité pro interpretaci. Když vidíme podlouhlý oblak bodů směřující zleva dole doprava nahoru, znamená to, že vedle celkového trendu stále existuje velký lokální rozptyl. Dva jedinci s téměř stejnou délkou ploutve nemusí mít stejnou hmotnost a dva podobně těžcí jedinci nemusí mít stejně dlouhou ploutev.

Abychom rozptýlení jedné proměnné vyjádřili přesně číslem, zavedeme **výběrový rozptyl** (anglicky *sample variance*; zkráceně také jen **rozptyl**) a z něj odvozenou výběrovou směrodatnou odchylku (anglicky *sample standard deviation*, zkratka **SD**; česky se používá také označení standardní odchylka).

Nejdřív jen slovy: **od každé hodnoty odečteme průměr, odchylky umocníme na druhou, sečteme je a součet vydělíme počtem pozorování minus jedna**. Jako příklad použijeme malý vzorek 4 tučňáků druhu Adelie (průměr délky ploutve: 188,8 mm). Tabulka ukazuje délku ploutve každého z nich, odchylku od průměru a čtverec té odchylky:

Tuč- ňák	Délka ploutve (mm)	Odchylka od průměru (188,8 mm)	Čtverec odchylky (mm ²)
1	181	-7.8	60.1
2	186	-2.8	7.6
3	190	1.2	1.6
4	198	9.2	85.6

Nejprve stejný výpočet zapíšeme pouze názvy veličin:

$$\text{výběrový rozptyl délky ploutve} = \frac{\text{součet čtverců odchylek délek ploutví od průměru}}{\text{počet tučňáků} - \text{jedna}}.$$

Teprve potom dosadíme délky ploutví a jejich průměr z tabulky:

$$\begin{aligned} \text{výběrový rozptyl délky ploutve} &= \frac{(181 - 188,8)^2 + (186 - 188,8)^2 + (190 - 188,8)^2 + (198 - 188,8)^2}{4 - 1} \\ &= \frac{60,1 + 7,6 + 1,6 + 85,6}{3} \\ &= \frac{154,8}{3} = 51,6 \text{ mm}^2 \end{aligned}$$

Teprve nyní výpočet zkrátíme symboly. Délku ploutve označíme x , její výběrový rozptyl s_x^2 a výběrovou směrodatnou odchylku s_x . Pro libovolný soubor n pozorování platí:

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_x = \sqrt{s_x^2}$$

Ve vzorci x_i označuje délku ploutve jednoho tučňáka, $\bar{x}$ průměrnou délku ploutve, n počet pozorování, s_x^2 výběrový rozptyl a s_x směrodatnou odchylku v původních jednotkách.

V celém souboru tučňáků vychází směrodatná odchylka délky ploutve přibližně 14.1 mm a tělesné hmotnosti přibližně 802 g. Tato čísla říkají, o kolik milimetrů nebo gramů se typický jedinec odchyluje od průměru celého souboru. V dalším kroku tuto myšlenku rozšíříme na dvě proměnné zároveň.

8 Proč jsou data rozptýlená

Variabilita v biologických datech není chyba, kterou bychom měli odstranit. Je to vlastnost reálného světa. Dva tučňáci mohou mít podobně dlouhou ploutev, ale lišit se druhem, pohlavím, věkem nebo celkovou tělesnou stavbou. K rozptylu přispívá i běžná nepřesnost měření a to, že žádný biologický vztah nebývá dokonale přesný.

Na tomto místě je užitečné rozlišit několik zdrojů rozptylu, které se v grafu míchají dohromady:

- **biologické rozdíly mezi jedinci:** dva podobní jedinci nemusí být stejně těžcí ani stejně stavěni

- **rozdíly mezi skupinami:** část variability vzniká tím, že v jednom grafu spojujeme více druhů
- **nepřesnost a omezení měření:** reálná data nikdy nejsou úplně bez chyby
- **další nevysvětlené vlivy:** sledujeme jen malou část toho, co hmotnost organismu ovlivňuje

V našem datasetu se délka ploutve pohybuje přibližně od 172 do 231 mm a tělesná hmotnost od 2700 do 6300 g. Už z tohoto rozsahu je vidět, že nejde o několik téměř stejných jedinců, ale o biologicky pestrý soubor měření.

9 Kovariance: jak se dvě proměnné pohybují společně

Rozptýl jedné proměnné popisuje, jak moc jsou její hodnoty rozptýleny kolem průměru. Jakmile ale sledujeme dvě proměnné zároveň, zajímá nás, zda se jejich odchylky od průměru pohybují *společně*. Tento souhrn se nazývá **kovariance** (anglicky *covariance*).

Nejdřív slovy: **u každého tučňáka vynásobíme odchylku délky ploutve od jejího průměru odchylkou hmotnosti od jejího průměru, součiny sečteme a vydělíme počtem pozorování minus jedna.** Když jedinci s nadprůměrně dlouhou ploutví mají také nadprůměrnou hmotnost, obě odchylky mají stejné znaménko a jejich součin je kladný. Pro stejný malý vzorek 4 tučňáků Adelie tabulka ukazuje všechny potřebné hodnoty:

Tuč- ňák	Odch. délky (mm), prům. 188,8 mm	Odch. hmotnosti (g), prům. 4050 g	Součin odchylek (mm·g)
1	-7.8	-300	2325
2	-2.8	-250	688
3	1.2	200	250
4	9.2	350	3238

Nejprve zapíšeme výpočet pouze názvy obou proměnných:

$$\text{výběrová kovariance délky ploutve a hmotnosti} = \frac{\text{součet součinů odchylek délky ploutve a hmotnosti}}{\text{počet tučňáků} - \text{jedna}}$$

Teprve potom dosadíme odchylky z tabulky:


$$\begin{aligned} \text{výběrová kovariance délky ploutve a hmotnosti} &= \frac{(-7,8) \cdot (-300) + (-2,8) \cdot (-250) + (1,2) \cdot (200) + (9,2) \cdot (350)}{4 - 1} \\ &= \frac{2325 + 688 + 250 + 3238}{3} \\ &= \frac{6500}{3} = 2167 \text{ mm} \cdot \text{g} \end{aligned}$$

V obecném zápisu označíme délku ploutve x , hmotnost y a jejich výběrovou kovarianci $\text{cov}(x, y)$. Pro n pozorování:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Zde x_i označuje délku ploutve jednoho tučňáka, y_i jeho hmotnost, $\bar{x}$ a $\bar{y}$ příslušné průměry, n počet tučňáků a $\text{cov}(x, y)$ výběrovou kovarianci obou proměnných.

Intuici si usnadníme grafem. Přidáme do bodového grafu dvě přerušované čáry – vertikální ve výši průměrné délky ploutve (200.9 mm) a horizontální ve výši průměrné hmotnosti (4202 g). Vzniknou čtyři kvadranty:



Obrázek 5: Bodový graf tučňáků s průměrnými čarami (přerušovaně). Oranžové kvadranty přispívají ke kovarianci kladně, fialové záporně.

🔍 Přečtěte si obrázek

Podívejte se na obrázek: ve kterých kvadrantech se shlukuje nejvíce bodů? Co to říká o tom, jakým směrem se délka ploutve a hmotnost pohybují spolu?

💡 Odpověď

Oranžové kvadranty (vpravo nahoře a vlevo dole) převažují — jedinci s nadprůměrně dlouhou ploutví mají zpravidla i nadprůměrnou hmotnost, a naopak. Kovariance proto bude kladná.

Oranžové kvadranty převažují — jedinci s delší ploutví mají zpravidla i větší hmotnost, a naopak. Kovariance proto vychází kladná: přibližně 9824 mm·g.

Kovariance ale závisí na jednotkách. Kdybychom přepočítali délku z milimetrů na centimetry, kovariance by se stokrát zmenšila. Abychom vztah popsali číslem nezávislým na jednotkách, musíme ji ještě přepočítat pomocí směrodatných odchylek obou proměnných. Nejdřív si to ukážeme na stejném malém vzorku a teprve potom zapíšeme obecný vzorec.

Na stejném malém vzorku 4 tučňáků si můžeme ukázat i plný výpočet Pearsonova r . Potřebujeme pro něj stejnou informaci jako před chvílí u kovariance, ale navíc i čtverce odchylek obou proměnných:

Tuč- ňák	Odch. délky (mm)	Odch. hmot- nosti (g)	Součin od- chylek	Čtverec odch. délky	Čtverec odch. hmotnosti
1	-7.8	-300	2325	60.1	90000
2	-2.8	-250	688	7.6	62500
3	1.2	200	250	1.6	40000
4	9.2	350	3238	85.6	122500

Teprve s obrázkem před očima přečteme, jak každý kvadrant přispívá ke kovarianci:

- **vpravo nahoře** ($x > \bar{x}, y > \bar{y}$): obě odchylky kladné – příspěvek kladný
- **vlevo dole** ($x < \bar{x}, y < \bar{y}$): obě odchylky záporné – součin je stále kladný $(-) \cdot (-) = (+)$
- **vpravo dole** ($x > \bar{x}, y < \bar{y}$): odchylky s opačnými znaménky – příspěvek záporný
- **vlevo nahoře** ($x < \bar{x}, y > \bar{y}$): odchylky s opačnými znaménky – příspěvek záporný

Nejprve zapíšeme normalizaci pouze názvy veličin:

$$\text{Pearsonův korelační koeficient} = \frac{\text{součet součinů odchylek délky ploutve a hmotnosti}}{\sqrt{\text{součet čtverců odchylek délky ploutve}} \cdot \sqrt{\text{součet čtverců odchylek hmotnosti}}}$$

Teprve potom dosadíme odchylky z tabulky:

$$\begin{aligned} \text{Pearsonův korelační koeficient} &= \frac{(-7,8) \cdot (-300) + (-2,8) \cdot (-250) + (1,2) \cdot (200) + (9,2) \cdot (350)}{\sqrt{[(-7,8)^2 + (-2,8)^2 + (1,2)^2 + (9,2)^2][(-300)^2 + (-250)^2 + (200)^2 + (350)^2]}} \\ &= \frac{2325 + 688 + 250 + 3238}{\sqrt{(60,1 + 7,6 + 1,6 + 85,6) \cdot (90000 + 62500 + 40000 + 122500)}} \\ &= \frac{6500}{\sqrt{154,8 \cdot 315000}} = 0,93 \end{aligned}$$

Tímto normalizováním dostaneme Pearsonův korelační koeficient, který leží vždy v intervalu $[-1, +1]$. V našich datech vychází přibližně 0,87 – přesně stejný výsledek jako přímý výpočet (0,87), jen odvozený jinou cestou.

Pearsonův korelační koeficient nyní označíme obvyklým symbolem r . Obecně jej můžeme zapsat bez jednotek takto:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Zde r označuje Pearsonův korelační koeficient, x_i a y_i dvojici hodnot jednoho tučňáka, $\bar{x}$ a $\bar{y}$ průměry obou proměnných a n počet pozorování. Čitatel shrnuje společný pohyb odchylek; jmenovatel jej převede na bezrozměrné měřítko.

10 Korelace jako stručný číselný popis

Graf je vždy první krok, ale někdy chceme vztah dvou numerických proměnných shrnout i číslem. K tomu slouží korelace. V datech tučňáků vychází Pearsonova korelace přibližně 0,87 a Spearmanova korelace přibližně 0,84. Pearsonovo r jsme před chvílí odvodili z kovariance – vydělíme kovarianci součinem směrodatných odchylek a dostaneme číslo v rozsahu $[-1, +1]$.

V R si obě čísla spočítáme přímo nad stejnými dvěma sloupci, které jsme předtím použili pro bodový graf:

```
cor(  
  # Pearsonova korelace shrnuje lineární vztah původních hodnot  
  x = data_tucnaci$delka_ploutve_mm,  
  y = data_tucnaci$hmotnost_g,  
  method = "pearson"  
)
```


```
[1] 0.8712018
```

```
cor(  
  # Spearmanova korelace místo hodnot porovnává jejich pořadí  
  x = data_tucnaci$delka_ploutve_mm,  
  y = data_tucnaci$hmotnost_g,  
  method = "spearman"  
)
```

```
[1] 0.8399741
```

Takto dostaneme dvě stručná čísla, která shrnují tutéž biologickou otázku trochu jiným způsobem: Pearson zdůrazňuje lineární vztah, Spearman pořadí hodnot.

Na schématu níže jsou čtyři typické situace. Všimněte si, jak se tvar bodového mraku mění a jak na různé hodnoty r reagují Pearson (P) a Spearman (S) odlišně.



Obrázek 6: Čtyři typické situace korelace: silná kladná lineární, žádná korelace, silná záporná lineární a monotónní, ale zakřivený vztah. U každého panelu jsou hodnoty Pearsonovy (P) a Spearmanovy (S) korelace.

- **Pearsonova korelace:** pracuje s původními hodnotami, shrnuje hlavně lineární vztah a bývá citlivější na odlehlé body.
- **Spearmanova korelace:** pracuje s pořadím hodnot, shrnuje monotónní vztah a bývá vůči odlehlým bodům odolnější.

Pearsonova korelace shrnuje, jak silně spolu souvisejí hodnoty na obou osách v lineárním smyslu. Spearmanova korelace pracuje s pořadím hodnot, takže je vhodná jako neparametrická alternativa tam, kde nás zajímá spíš monotónní vztah než přesně lineární průběh. Bývá také méně citlivá na odlehlé body.

Když body tvoří přibližně rostoucí oblak bez výrazné zvláštních bodů, bývají obě korelace podobné. Pokud by byl vztah zakřivený nebo by několik bodů silně vyčnívalo, mohl by být rozdíl mezi Pearsonem a Spearmanem už informativní sám o sobě.

V této lekci je důležité hlavně to, že obě čísla mají podpůrnou roli. Nenahrazují graf ani biologickou interpretaci. Pomáhají jen stručně vyjádřit, že delší ploutve bývají spojeny s vyšší hmotností a že tento vztah je v datech zřetelný i po převodu do číselné podoby.

11 Korelace není kauzalita

V této chvíli už umíme vztah dvou číselných proměnných dobře popsat slovně i číslem. Je ale důležité nepřekročit hranici toho, co nám korelace opravdu říká. Korelace popisuje, že se dvě proměnné mění společně, ale sama o sobě ještě neukazuje, která proměnná je příčinou druhé.

U tučňáků tedy můžeme bezpečně říct, že delší ploutev bývá spojena s vyšší hmotností. Nemůžeme ale jen z korelace uzavřít, že změna délky ploutve přímo způsobuje změnu hmotnosti. Část vztahu může vznikat i tím, že obě proměnné souvisejí s celkovou velikostí těla nebo s druhem.

To je důvod, proč po vizualizaci a korelaci obvykle následuje modelování. Až model nám pomáhá oddělit, co je společný vzor v datech, co je efekt konkrétní proměnné a jak velká je nejistota kolem tohoto odhadu.

! Co je správná interpretace?

- **A:** Kladná korelace znamená, že jsme prokázali příčinný vztah.
- **B:** Kladná korelace znamená, že proměnné spolu souvisejí, ale příčinu musíme řešit opatrněji.
- **C:** Korelace je jen technické číslo bez biologického významu.


i Odpověď

Správně je **B**. Korelace je biologicky užitečný souhrn společného vzoru v datech, ale sama ještě nerozlišuje přímou příčinu od dalších možných vysvětlení.

12 Stejný graf, ale s viditelnými druhy

Teď se můžeme vrátit ke stejnému bodovému grafu a odkrýt ještě jednu informaci: druh tučňáka. Původní šedý oblak bodů se rozpadne na několik podskupin, které se částečně překrývají, ale zároveň mají vlastní polohu a vlastní rozptyl.

To je důležité didakticky i biologicky. V původním bodovém grafu jsme viděli „jeden“ vztah, ale část tohoto vztahu je tvořena tím, že různé druhy mají různé typické kombinace délky ploutve a hmotnosti. Jinými slovy: část rozptylu není jen náhodný šum, ale odráží i skutečnou strukturu dat.



Jakmile jsou druhy vidět, je snazší pochopit, proč byl původní rozptyl tak široký. Část variability vzniká uvnitř druhů, ale část je dána i tím, že v jednom obrázku mícháme více biologicky odlišných

skupin. To je přesně okamžik, kdy nám doplňková kategoriální proměnná pomůže lépe číst vztah dvou číselných proměnných.

13 Jak typ proměnných určuje výběr grafu


Typ grafu nevybíráme podle toho, co je „hezčí“, ale podle toho, jaký vztah mezi proměnnými chceme přečíst. Jinak čteme dvě číselné osy, jinak porovnáváme skupiny proti číslům a jinak sledujeme složení dvou kategoriálních proměnných.

Jako rychlá pomůcka pomáhají dvě otázky:

- Jsou obě proměnné číselné?
- Nebo jedna z nich hlavně rozděluje pozorování do skupin?

13.1 Dvě numerické proměnné: délka ploutve a hmotnost

Právě proto jsme v této lekci začali bodovým grafem (anglicky *scatter plot*). Když jsou obě proměnné numerické, bývá bodový graf nejlepší první volbou: každý bod nese dvojici hodnot a my můžeme najednou číst směr vztahu, sílu rozptylu, možné shluky i odlehlé body.




Obrázek 7: Dvě numerické proměnné: bodový graf je přirozený první krok, protože každý bod nese dvojici hodnot současně.

U tučňáků jsme v něm viděli, že delší ploutve bývají spojené s vyšší hmotností, ale také že vztah není dokonale těsný. Právě to je důvod, proč bodový graf nepřeskakovat. Žádné jediné číslo nám neukáže tvar oblaku bodů tak přímo.

Když ale chceme ve stejných datech zvýraznit jinou vlastnost vztahu, můžeme použít i několik dalších variant. Každá z nich ukazuje něco trochu jiného.


13.1.a Hladký trend (*fitted trend line*)

Čára pomáhá rychle přečíst hlavní směr vztahu, ale body pořád zůstávají viditelné.




13.1.b Hustota v mřížce (2D histogram)

Když je bodů hodně, můžeme místo jednotlivých bodů ukázat, kde se měření hromadí nejvíce.




13.1.c Po druzích v panelech (*small multiples*)

Rozdělení do panelů pomáhá odlišit, co je společný trend a co je rozdíl mezi skupinami.



13.2 KATEGORIÁLNÍ A NUMERICKÁ PROMĚNNÁ: DRUH A HMOTNOST

Jakmile nás začne zajímat přímo vztah mezi druhem a tělesnou hmotností, bodový graf už není nejpřirozenější první volbou. Teď totiž nesrovnáváme dvě číselné osy, ale kategoriální proměnnou určující skupiny a numerickou proměnnou, která se mezi nimi porovnává.



Než si přečtete vysvětlení, zkuste si v grafu najít tři věci:

- Který druh leží typicky nejvýš?
- Kde se rozdělení hmotnosti mezi druhy překrývá a kde už méně?
- Je rozptýl uvnitř jednotlivých druhů malý, nebo i v rámci jednoho druhu zůstává docela velký?

i Odpověď

Tučňáci druhu Gentoo leží typicky nejvýš. Adelie a Chinstrap se vzájemně překrývají více. I uvnitř každého druhu je viditelný rozptyl – takže ani znalost druhu sama o sobě nestačí k přesnému odhadu hmotnosti konkrétního jedince.


Na tomto grafu nečteme směr vztahu jako v bodovém grafu. Místo toho sledujeme, zda se rozdělení tělesné hmotnosti mezi druhy překrývá, nebo zda některé skupiny leží typicky výš či níž. I to je vztah dvou proměnných: hodnota jedné proměnné se mění podle úrovně druhé.

Na první pohled se zdá, že tučňáci druhu Gentoo leží typicky výš než Adelie a Chinstrap. Zároveň ale skupiny nejsou úplně oddělené a i uvnitř každého druhu zůstává viditelný rozptyl. Pro tuto kombinaci typů proměnných je proto často přirozenější krabicový graf (anglicky *box plot*) nebo body rozdělené do skupin než klasický bodový graf.

Totéž srovnání ale můžeme nakreslit i jinak podle toho, zda chceme zdůraznit jednotlivé body, šířku skupin nebo jen jejich shrnutí.


13.2.a Samotné body (*beeswarm plot*)

Nejlépe ukazují jednotlivá měření a překryv skupin, ale hůře shrnují jejich střed.




13.2.b Krabice bez bodů (*box plot*)

Rychle shrnou polohu a překryv skupin, ale skryjí jemnější tvar rozložení uvnitř každého druhu.



13.2.c Šířka rozložení (*violin plot*)

Hladký obrys dává lepší představu o tom, kde je v každé skupině více a méně hodnot.



Další užitečný případ jsou dvě kategoriální proměnné najednou.

13.3 Druh a kategorie délky ploutve

Jinou situaci dostaneme, když obě proměnné rozdělují data do skupin. Abychom si to ukázali na stejných datech, rozdělíme délku ploutve do tří seřazených kategorií: kratší, střední a delší. Je to jen didaktická ukázka kombinace typů proměnných, ne doporučený první analytický krok pro spojitou proměnnou. Teď už nechceme číst přesné číselné hodnoty na ose y, ale složení skupin podle podílů.



U takového grafu nás zajímá něco jiného než u boxplotu. Neptáme se, jaká je typická hodnota, ale jaké je zastoupení druhů uvnitř jednotlivých kategorií délky ploutve. Proto se zde velmi hodí proporční skládaný sloupcový graf (anglicky *proportional stacked bar chart*): každá skupina má stejnou výšku 100 % a my snadno porovnáváme podíly.

Než si přečtete vysvětlení, zkuste odhadnout:

- Ve které kategorii délky ploutve má druh Gentoo největší podíl?
- Kde naopak převažuje Adelie?
- Vypadá kategorie středních ploutví druhově smíšeněji než krajní kategorie?


i Odpověď

Gentoo má nejvyšší podíl mezi delšími ploutvemi, zatímco Adelie převažuje mezi kratšími ploutvemi. Střední kategorie bývá druhově smíšenější. Právě tuto změnu ve složení skupin proporční sloupcový graf ukazuje velmi přehledně.

Stejná dvojice kategoriálních proměnných se ale dá zobrazit i jinými způsoby podle toho, zda chceme zdůraznit podíly, absolutní počty nebo přehled celé tabulky najednou.


13.3.a Proporce (*proportional stacked bar chart*)

Když mají mít všechny sloupce stejnou výšku, snadno porovnáváme složení kategorií mezi sebou.




13.3.b Absolutní počty (*grouped bar chart*)

Vedle sebe postavené sloupce se hodí tehdy, když nás zajímá i velikost jednotlivých skupin, nejen jejich složení.



13.3.c Tepelná mapa (*heat map*)


Když chceme rychle přehledně celou tabulku kombinací, je praktické převést ji na barevnou mřížku.



13.3.d Dlaždicový graf (*waffle chart*)

Každý čtvereček představuje 1 % dané kategorie. Tento typ grafu se hodí tehdy, když chceme podíly ukázat ještě doslova a po malých dílcích.

Dlaždicový graf: 100 dílků pro každou kategorii délky ploutve




Ještě jiný případ je seřazená osa proti numerické proměnné.

13.4 Seřazené kategorie délky ploutve a hmotnost

Stejně vytvořené kategorie můžeme použít ještě jinak: jako ordinální proměnnou na ose x a hmotnost jako numerickou proměnnou na ose y. V takové chvíli je užitečný opět krabicový graf (anglicky *box plot*), ale tentokrát je zásadní, že pořadí kategorií na ose nese informaci.

Ordinální + numerická proměnná: záleží i na pořadí kategorií



Než si přečtete vysvětlení, zkuste si všimnout tří věcí:

- Posouvá se typická hmotnost od kratších ploutví k delším?
- Kde se skupiny ještě překrývají a kde už méně?
- Co by se ztratilo, kdybychom pořadí kategorií na ose x promíchali?


Tentokrát neporovnáváme nepojmenované skupiny, ale seřazené stupně. Proto má smysl sledovat, zda se s rostoucí kategorií posouvá i typická hmotnost. Kdybychom pořadí kategorií na ose promíchali, velká část sdělení grafu by se ztratila.

I zde ale existuje více rozumných variant. Některé lépe ukazují jednotlivá pozorování, jiné zase co nejstručnější souhrn podle pořadí.

13.4.a Samotné body (*beeswarm plot*)


Když chceme ponechat všechna měření viditelná, stačí je rozložit do stran v jednotlivých kategoriích.

Všechna měření v seřazených kategoriích




13.4.b Spojené středy (*line plot of group summaries*)

Pokud chceme co nejrychleji číst posun od kratších k delším kategoriím, pomůže jednoduché spojení typických hodnot.



13.4.c Šířka rozložení (*violin plot*)

Hladký obrys pomůže ukázat, kde jsou v každé seřazené skupině data koncentrovaná a kde naopak řidká.



i Poznámka k tomuto příkladu

Kategorie kratší, střední a delší jsme zde vytvořili uměle z číselné proměnné jen proto, abychom si ukázali práci s ordinální proměnnou. Stejný typ grafu bychom ale použili i pro přirozeně seřazené biologické škály, například malý–střední–velký nebo nízký–střední–vysoký.

13.5 Rychlá tabulka: který graf zvolit jako první?

Typ proměnných	Co chceme zobrazit	Dobrý první graf	Co v něm hledat
jedna numerická	Jak vypadá rozdělení jedné číselné proměnné	histogram	tvár rozdělení, rozptyl, odlehlé body
jedna kategoriální proměnná	Kolik pozorování padá do jednotlivých skupin	sloupcový graf	četnosti, podíly, nerovnováha skupin
numerická + numerická	Jak spolu souvisejí dvě číselné proměnné	bodový graf	směr vztahu, tvar oblaku bodů, shluky, odlehlé body
kategoriální + numerická	Jak se liší číselná proměnná mezi skupinami	boxplot + body	typická hodnota, překryv skupin, vnitroskupinový rozptyl
kategoriální + kategoriální	Jak se mezi skupinami mění složení kategorií	skládaný sloupcový graf s proporciemi	rozdíly v podílech mezi skupinami
ordinální + numerická	Jak se mění číselná proměnná napříč seřazenými stupni	boxplot se seřazenou osou	posun mediánu, překryv, monotónní trend

Tahle tabulka není seznam všech možných grafů. Je to bezpečný první krok pro situaci, kdy si nejdřív potřebujeme ujasnit, co vlastně porovnáváme. Až potom má smysl přidávat další vrstvy, jemnější styl nebo formálnější model.

14 Co zatím ještě nemůžeme tvrdit

! Která formulace je v této chvíli správně?

- **A:** V grafu je vidět vztah, takže jsme prokázali efekt.
- **B:** V datech je vidět biologicky smysluplný vzor, který chceme popsat přesněji.
- **C:** Protože body neleží na jedné přímce, mezi proměnnými žádný vztah není.

i Odpověď

Nejllepší odpověď je **B**. Graf ukazuje vzor, ale nestačí k prokázání efektu — k tomu potřebujeme model, odhad velikosti vztahu a kvantifikaci nejistoty.


Častý omyl zní: v grafu je vidět vztah, takže jsme prokázali efekt. To je předčasný závěr. Z grafu zatím víme, že data vypadají zajímavě a že stojí za další analýzu. Nevíme ještě, jak přesně vztah popsat, jak je silný a jak velká je nejistota kolem našeho odhadu.

Správná formulace pro tuto chvíli je skromnější: v datech vidíme vzor, který je biologicky smysluplný a který chceme v dalších lekcích popsat přesněji.

15 Co bude následovat dál

V další lekci navážeme lineárním modelem, který nám pomůže převést viditelný vzor do číselné podoby. Teprve potom bude dávat smysl mluvit o tom, jak velký vztah mezi proměnnými je a jak moc mu věříme.

Palmer Penguins ale nabízí i další proměnné, které se budou hodit pro pozdější příklady, například délku a hloubku zobáku. Stejná logika výběru grafu a interpretace vztahu se pak bude dát použít i na jiné biologické otázky než jen na délku ploutve a hmotnost.



Obrázek 8: Schéma měření délky a hloubky zobáku v datech Palmer Penguins. Ilustrace: Allison Horst.

16 Shrnutí

- Nejprve se vyplatí dobře přechíst jeden bodový graf dvou numerických proměnných a teprve potom přidávat další vrstvy informace.
- V bodovém grafu sledujeme rozptyl ve dvou směrech současně, ne jen odchylku kolem jediné hodnoty.
- Korelace je stručný číselný popis vztahu dvou numerických proměnných, ale sama o sobě nenahrazuje graf ani interpretaci.

- Doplnková kategoriální proměnná může odhalit, že část původního rozptylu souvisí se skutečnou strukturou dat.
- Typ grafu vybíráme podle dvojice proměnných: pro numerická data často bodový graf, pro kategoriální a numerickou proměnnou často boxplot nebo body rozdělené do skupin.
- V grafu můžeme rozpoznat směr vztahu, ale ještě tím neprokazujeme efekt.
- Tato lekce připravuje půdu pro dva další kroky: v následující lekci přidáme modelový odhad velikosti vztahu a potom vyjádříme nejistotu tohoto odhadu pomocí intervalu spolehlivosti.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice. Úplný průběžně aktualizovaný slovníček je dostupný také [online](#).

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>