

Vztahy dvou proměnných a vizualizace

Biostatistika - L02

 Ondřej Mottl

[Moodle](#)

Výsledky učení

Po dnešní přednášce budete schopni:

- přečíst první bodový graf pro dvě numerické proměnné
- vysvětlit, co nám ukáže rozptyl a co přidá korelace
- zvolit vhodný první graf podle typu dvojice proměnných
- rozlišit mezi viditelným vzorem v datech a silnějším tvrzením o efektu

Biologická otázka


Chceme zjistit:

Mají tučňáci s delší ploutví vyšší tělesnou hmotnost?

Dnes ještě nebudeme testovat hypotézu.

Dnes chceme umět:

- dobře se podívat na data
- všimnout si směru a rozptylu
- poznat, co už z grafu říct můžeme a co ještě ne



Ilustrace: Allison Horst

Odhad před prvním grafem

Který popis čekáte nejspíš?

MOŽNOST A

**Téměř jisté
pravidlo**

Delší ploutev téměř vždy
znamená vyšší hmotnost.

MOŽNOST B

**Trend, ale ne
dokonale**

Delší ploutev bude s vyšší
hmotností souviset, ale ne
dokonale.


MOŽNOST C

Bez vztahu

Délka ploutve a hmotnost
spolu souviset nebudou.

Když nehlasujeme: zvedněte ruku pro možnost, která vám dává největší biologický smysl.

První pohled na data



Než něco pojmenujeme

Nejdřív 20 sekund ticha: napište si jednu větu, co z grafu opravdu vidíte.

HLEDEJTE V GRAFU

Směr

Je hlavní směr spíš
rostoucí, nebo ne?

HLEDEJTE V GRAFU

Šířku oblaku



Je oblak bodů úzký, nebo
široký?

HLEDEJTE V GRAFU



Místa ke zpomalení

Vidíte body nebo části
grafu, kde stojí za to ptát
se dál?

Stejná data, jiné osy



Rozptyl čteme ve dvou směrech



PŘI PODOBNÉ PLOUTVI

Hmotnost se stále liší

- I v úzkém svislém pruhu vidíme více různých hmotností.
- Rozptyl tedy nečteme jen podle hlavního směru oblaku.

PŘI PODOBNÉ HMOTNOSTI

Délka ploutve se stále liší

- Stejně můžeme číst i vodorovný směr.
- Rozptyl je vlastnost vztahu, ne jen jedna odchylka od čáry.

Vracíme se k biologické otázce

Co už po těchto třech pohledech umíme říct?

CO UŽ VIDÍME

Signál

- Delší ploutve bývají spojeny s vyšší hmotností.
- Celkový směr je zřetelně rostoucí.

CO JEŠTĚ ZŮSTÁVÁ OTEVŘENÉ

Rozptyl

- Vztah není dokonale těsný.
- Rozptyl čteme ve dvou směrech: při podobné ploutvi i při podobné hmotnosti.

Už máme **biologicky smysluplný vzor**, ale ještě ne model, odhad efektu ani nejistotu.

Co už můžeme tvrdit?

Která formulace je v této chvíli nejlepší?

MOŽNOST A

Příliš silné tvrzení

V grafu je vidět vztah, takže jsme prokázali efekt.

MOŽNOST B

Přiměřený závěr

V datech je vidět biologicky smysluplný vzor, který chceme popsat přesněji.

MOŽNOST C

Příliš slabé tvrzení

Protože body neleží na jedné přímce, mezi proměnnými žádný vztah není.

Když nehlasujeme: napište si písmeno, které byste obhajovali před spolužákem.

Správně je B

CO UŽ VÍME

Viditelný vzor je důležitý začátek

- Vidíme směr vztahu.
- Vidíme rozptyl kolem hlavního směru.
- Vidíme, že otázka stojí za přesnější popis.

CO JEŠTĚ NEMÁME


Zatím chybí další krok

- model, který vztah popíše přesněji
- odhad velikosti vztahu
- kvantifikace nejistoty kolem odhadu

Nejdřív malý příklad v R

Toto je záměrně malý didaktický příklad se čtyřmi dvojicemi hodnot, jen abychom viděli logiku příkazu.


```
1 vec_delka_ploutve_mm <-  
2   c(186, 191, 197, 204)  
3  
4 vec_hmotnost_g <-  
5   c(3800, 3920, 4300, 4480)  
6  
7 plot(  
8   x = vec_delka_ploutve_mm,  
9   y = vec_hmotnost_g,  
10  xlab = "Délka ploutve (mm)",  
11  ylab = "Tělesná hmotnost (g)",  
12  pch = 16,  
13  col = rgb(red = 0.95, green = 0.65, blue = 0.07, alpha = 0.5),  
14 )
```



Nejdřív si stejný nápad zkusíme na pár konkrétních dvojicích hodnot. Pak úplně stejnou logiku použijeme na všechny tučňáky najednou.

A teď stejné pro všechny tučňáky

```
1 plot(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   xlab = "Délka ploutve (mm)",  
5   ylab = "Tělesná hmotnost (g)",  
6   pch = 16,  
7   col = rgb(red = 0.54, green = 0.54, blue = 0.54, a  
8 )
```



Co když je v oblaku skrytá struktura?

Než přidáme další vrstvu, odhadněte:

MOŽNOST A

**Barvy nic
nepřidají**

Barvy nic důležitého
nezmění.

MOŽNOST B

**Skupiny mohou
něco vysvětlit**

Barvy mohou ukázat
skupiny, které část
rozptylu vysvětlují.


MOŽNOST C

**Vztah by se měl
ztratit**

Po rozdělení podle druhu
zmizí veškerý vztah.

Když nehlasujeme: zvedněte ruku pro možnost, kterou byste chtěli ověřit jako první.

Stejná data, ale s druhem



Co se po obarvení změnilo?

CO ZŮSTALO STEJNÉ

Celkový vztah nezmizel

- Delší ploutve jsou stále spojeny s vyšší hmotností.
- Hlavní směr oblaku pořád dává biologický smysl.

CO SE ZPŘESNILO

Rozptyl už není jen „šum“


- Část variability souvisí s tím, že mícháme více druhů dohromady.
- Jedno číslo pro všechny body může skrýt důležitou biologickou strukturu.

Jak převést směr oblaku do čísla?

Nejdřív pomocná myšlenka:

Když se obě proměnné pohybují stejným směrem od svého průměru, mělo by to zvyšovat souhrnné číslo vztahu.

Nejprve jen střed grafu



Které části grafu pomáhají kladné kovarianci?

Než něco vybarvíme, odhadněte:

MOŽNOST A

**Vpravo nahoře a
vlevo dole**

Obě proměnné jsou tam
na stejné straně od svého
průměru.

MOŽNOST B

**Vlevo nahoře a
vpravo dole**

Jedna proměnná je nad
průměrem a druhá pod
ním.


MOŽNOST C

Všechny stejně

Na poloze bodů vůči
středu by nezáleželo.

Když nehlasujeme: ukažte prstem do dvojice kvadrantů, které byste vybrali.

Takto vypadá kladná kovariance



Proč samotná kovariance nestačí

V MILIMETRECH A GRAMECH

Kovariance 9 824

Směr vztahu je kladný, ale číslo pořád závisí na použitých jednotkách.

V CENTIMETRECH A
KILOGRAMECH

Kovariance 0,982

Biologický vztah je stejný, ale velikost čísla se po změně jednotek změní.

Směr vztahu se nezměnil, ale velikost čísla ano. Proto chceme **bezrozměrný souhrn**: korelaci.

Dvě čísla, která budeme používat

PEARSON

Lineární čtení vztahu

- shrnuje hlavně lineární vztah
- v našich datech vychází 0,87

SPEARMAN

Pořadí a monotónní směr

- sleduje pořadí hodnot a monotónní vztah
- v našich datech vychází 0,84

Obě čísla jsou **doplněk ke grafu**, ne jeho náhrada.

Odhad před odhalením

Ve které situaci by se Pearson a Spearman mohly rozejít nejvíc?

MOŽNOST A

**Silný lineární
vztah**

Bez zvláštních bodů.

MOŽNOST B

**Žádná zřetelná
souvislost**

Obě čísla by měla být
nízká.


MOŽNOST C

**Monotónní, ale
zakřivený vztah**

Pořadí sedí, linearita už
ne úplně.

Když nehlasujeme: napište si A, B, nebo C a krátce proč.


Monotónní, ale zakřivený vztah



Čtyři situace najednou


Silná kladná lineární

P 1,00 | S 1,00




Žádná zřetelná souvislost

P 0,16 | S 0,11




Silná záporná lineární

P -1,00 | S -1,00



Monotónní, ale zakřivený

P 0,98 | S 1,00



Co nám to říká právě o tučňácích?

DOBŘÁ ZPRÁVA

Obě korelace si tu rozumějí

- U tučňáků jsou Pearson i Spearman velmi podobné.
- Celkový vztah je monotónní a zároveň docela blízký lineárnímu.

CO TÍM POŘÁD NEVYSVĚTLÍME


Jedno číslo nestačí na celou biologii

- Barva podle druhu ukazuje další strukturu.
- Samotná korelace neřekne, odkud se vztah bere.

Nejdřív malý příklad korelace v R

Použijeme stejný malý didaktický příklad, jen místo obrázku teď zkusíme spočítat číslo, které ten vztah shrne.

```
1 vec_delka_ploutve_mm <-  
2   c(186, 191, 197, 204)  
3  
4 vec_hmotnost_g <-  
5   c(3800, 3920, 4300, 4480)  
6  
7 cor(  
8   x = vec_delka_ploutve_mm,  
9   y = vec_hmotnost_g,  
10  method = "pearson"  
11 )  
12  
13 cor(  
14   x = vec_delka_ploutve_mm,  
15   y = vec_hmotnost_g,  
16   method = "spearman"  
17 )
```



CO TEN PŘÍKAZ SHRNUJE

Pořadí i směr jdou stejně

- Delší ploutev znamená v tomto

A stejné příkazy pro všechny tučňáky

```
1 cor(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   method = "pearson"  
5 )  
6  
7 cor(  
8   x = data_tucnaci$delka_ploutve_mm,  
9   y = data_tucnaci$hmotnost_g,  
10  method = "spearman"  
11 )
```

```
[1] 0.8712018
```

```
[1] 0.8399741
```

Krátký výstup stačí číst takto:
Pearson zdůrazňuje lineární
vztah, Spearman pořadí hodnot.

Co z korelace ještě neplyne?

Můžeme z tohoto vztahu tvrdit, že delší ploutev způsobuje vyšší hmotnost?

MOŽNOST A

Vysoká korelace už stačí

Ano, protože vysoká korelace sama ukazuje příčinný mechanismus.

MOŽNOST B

Asociace ano, kauzalita ne

Vidíme asociaci, ale sama korelace neukazuje příčinný mechanismus.

MOŽNOST C

Shoda dvou koeficientů je důkaz

Ano, pokud jsou Pearson a Spearman podobné, máme kauzalitu potvrzenou.

Když nehlasujeme: zkuste jednou větou obhájit možnost, kterou byste vybrali.

Správně je B

CO KORELACE ŘÍKÁ

Společná změna dvou proměnných

- Korelace popisuje, že se dvě proměnné mění společně.
- Pomáhá shrnout směr a těsnost vztahu.

CO KORELACE NEŘÍKÁ

Sama neoddělí příčinu

- neoddělí příčinu od dalších proměnných nebo společného mechanismu
- u tučňáků může část vztahu souviset i s druhem nebo celkovou velikostí těla

Který první graf se hodí?

DVOJICE 1

Délka ploutve × hmotnost

Obě proměnné jsou numerické.

DVOJICE 2

Druh × hmotnost

Jedna proměnná tvoří skupiny, druhá je numerická.

DVOJICE 3

Druh × ostrov

Obě proměnné jsou kategoriální.

Ke každé dvojici si přiřad'te první graf, po kterém byste sáhli.




- bodový graf
- boxplot nebo body ve skupinách
- tabulka četností nebo dlaždicový graf

ZAČNĚTE VŽDY STEJNĚ

Co si řeknu jako první?

- Jsou proměnné numerické, nebo kategoriální?
- Co z jejich vztahu chci v grafu přečíst?

Tři rychlé příklady



Pravidlo pro první volbu grafu

DVĚ NUMERICKÉ
PROMĚNNÉ

Bodový graf

Chceme číst směr vztahu
a rozptyl bodů.

KATEGORIÁLNÍ +
NUMERICKÁ

Boxplot nebo body ve skupinách

Chceme porovnat rozdíly
mezi skupinami.

DVĚ KATEGORIÁLNÍ
PROMĚNNÉ

Tabulka četností nebo dlaždicový graf

Chceme číst četnosti
kombinací.

První volbu grafu neurčuje to, co vypadá nejhezčí, ale **typ dvojice proměnných a otázka, kterou chceme číst.**

Co nám přidá model?

Když do stejného bodového grafu přidáme přímku, co se dozvíme navíc oproti samotnému korelačnímu koeficientu?


ZAČNĚTE TOUTO VĚTOU

Přímka by nám mohla ukázat...

- směr a velikost změny
- typický sklon vztahu
- most od grafu k modelu

Když nehlasujeme: zkuste si dopsat jednu větu začínající slovy „Přímka by nám mohla ukázat...”

Příště přidáme model



Shrnutí

- Pro dvě numerické proměnné je první volbou bodový graf.
- Z grafu čteme současně směr vztahu i šířku rozptylu.
- Korelace vztah shrne číslem, ale nenahradí samotný graf.
- Viditelný vzor ještě není důkaz efektu ani kauzality.
- Další krok je model, který přidá odhad efektu a nejistotu.

Závěrečná otázka

Co ještě potřebujeme, abychom z viditelného vzoru v grafu přešli k přesnějšímu tvrzení o velikosti efektu a nejistotě?