

# Vztahy dvou proměnných a vizualizace

Biostatistika - L02


 Ondřej Mottl

Moodle

# Pomůže nám druhá proměnná?

## NAŠE BIOLOGICKÁ OTÁZKA

Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?



Ilustrace: Allison Horst

# Výsledky učení

Po dnešní přednášce budete schopni:

- přečíst první bodový graf pro dvě numerické proměnné
- vysvětlit, co nám ukáže rozptyl a co přidá korelace
- zvolit vhodný první graf podle typu dvojice proměnných
- rozlišit mezi viditelným vzorem v datech a silnějším tvrzením o efektu

# Co si neseme z L01?

## JEDNA PROMĚNNÁ

Umíme určit její typ, popsat rozdělení a zvolit graf, který nic podstatného neskrývá.

## DNES PŘIDÁME DRUHOU

Jak poznáme směr, těsnost a biologicky důležitou strukturu vztahu?

# Diskuze se sousedem

## NAŠE BIOLOGICKÁ OTÁZKA


Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?

**Jak by podle vás mohl vypadat graf pro zodpovězení této otázky?**

*30 s přemýšlení — pak sdílejte svůj odhad se sousedem.*


# Naše data

```
1 vec_delka_ploutve_mm <-  
2   c(  
3     186, # tučňák 1  
4     191 # tučňák 2  
5   )  
6  
7 vec_hmotnost_g <-  
8   c(  
9     3800, # tučňák 1  
10    3920 # tučňák 2  
11  )  
12  
13 plot(  
14   x = vec_delka_ploutve_mm,  
15   y = vec_hmotnost_g,  
16   xlab = "Délka ploutve (mm)",  
17   ylab = "Tělesná hmotnost (g)",  
18   pch = 16  
19 )
```




# Naše data

```
1 vec_delka_ploutve_mm <-  
2   c(  
3     186, # tučňák 1  
4     191, # tučňák 2  
5     197, # tučňák 3  
6     204 # tučňák 4  
7   )  
8  
9 vec_hmotnost_g <-  
10  c(  
11    3800, # tučňák 1  
12    3920, # tučňák 2  
13    4300, # tučňák 3  
14    4480 # tučňák 4  
15  )  
16  
17 plot(  
18   x = vec_delka_ploutve_mm,  
19   y = vec_hmotnost_g,  
20   xlab = "Délka ploutve (mm)",  
21   ylab = "Tělesná hmotnost (g)",  
22   pch = 16
```




# Naše data

```
1 plot(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   xlab = "Délka ploutve (mm)",  
5   ylab = "Tělesná hmotnost (g)",  
6   pch = 16  
7 )
```




# Co už v tomto grafu vidíme?




- **Směr**: rostoucí
- **Rozptyl**: pořád široký
- **Závěr**: vzor vidíme, efekt zatím netvrdíme

# Stejná data, jiné osy




Délka ploutve na ose x




Hmotnost na ose x

# Rozptyl čteme ve dvou směrech



Podobná délka ploutve, různá  
hmotnost



Podobná hmotnost, různá délka  
ploutve

Když čteme bodový graf, díváme se současně na **směr vztahu** i na to, jak široký oblak zůstává v obou směrech.

# Vracíme se k biologické otázce

*Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?*

## Signál

Delší ploutve **bývají spojeny** s vyšší hmotností.

## Rozptyl

Vztah **není** dokonale těsný.

## POZOR

Vzor v grafu ještě není model, efekt ani nejistota.


## CO UŽ MŮŽEME TVRDIT?

Která formulace je v této chvíli nejlepší?

- a. V grafu je vidět vztah, takže jsme prokázali efekt.
- b. V datech je vidět biologicky smysluplný vzor, který chceme popsat přesněji.
- c. Protože body neleží na jedné přímce, mezi proměnnými žádný vztah není.

Než hlasujeme: přesvědčte souseda, proč jste vybrali svoji možnost.


# Stejná data, ale s druhem



# Co se po obarvení změnilo?

## BIOLOGICKÁ LOGIKA PLATÍ I PO OBARVENÍ PODLE DRUHU

- **Směr** oblaku zůstává kladný
  - *větší tučňák má delší ploutev.*
- **Rozptyl** má biologickou strukturu
  - Část variability pochází z míchání více druhů



# Kdybychom chtěli jedno číslo pro souhrn všech dat?

CO BY TAKOVÉ ČÍSLO MUSELO UMĚT?


**Směr** + **těsnost** + stejné měřítko pro různé jednotky

ŘEKNĚTE SOUSEDОВI ASPOŇ JEDNU VLASTNOST

30 s každý — pak porovnejte, co jste vymysleli.


# Kovariace

# Nejprve průměry grafu




Střed grafu určíme dvěma průměry: délka 200.9 mm, hmotnost 4202 g.

# Jeden bod pod lupou



**BOD NAD PRŮMĚREM V OBOU PROMĚNNÝCH**

Stejné znaménko odchylek → **kladný** příspěvek.



# Ve které další části grafu budou součiny také kladné?



## II. a III. kvadrant

Vpravo nahoře a vlevo dole — obě odchylky mají vždy stejné znaménko.

## I. a IV. kvadrant


Vlevo nahoře a vpravo dole — odchylky mají opačná znaménka.

## Všechny čtyři stejně

Na poloze vůči středu nezáleží.

Než hlasujeme: vysvětlíte sousedovi znaménka obou odchylek v jedné možnosti.

# Projdeme čtyři tučňáky ručně



| Délka | Hmotnost | Délka odch. | Hmotnost odch. |
|-------|----------|-------------|----------------|
| 186   | 3800     | -8.5        | -325           |
| 191   | 3920     | -3.5        | -205           |
| 197   | 4300     | 2.5         | 175            |
| 204   | 4480     | 9.5         | 355            |

Průměry:

Délka ploutve: **194.5** mm

Hmotnost: **4125** g

# Kovariance je “průměr součinů odchylek”

kovariance = **součet součinů odchylek** / (**počet pozorování** - 1)

Kovariance sčítá, jestli body leží převážně v kladných nebo záporných částech grafu.

| Délka<br>odch. | Hmotnost<br>odch. | Součin |
|----------------|-------------------|--------|
| -8.5           | -325              | 2762.5 |
| -3.5           | -205              | 717.5  |
| 2.5            | 175               | 437.5  |
| 9.5            | 355               | 3372.5 |

součet součinů odchylek = 7290

počet pozorování - 1 = 3

kovariance =  $7290 / 3 = \mathbf{2430 \text{ mm} \cdot \text{g}}$

# Prakticky stejné číslo nám dá funkce `cov()`.

```
1 soucin <- sum(  
2   data_priklad_vztahu_kovariance$soucin_odchylek  
3 )  
4 pocet_pozorovani_minus_one <-  
5   nrow(data_priklad_vztahu_kovariance) - 1  
6 kovariance <-  
7   vec_soucin / pocet_pozorovani_minus_one  
8 kovariance
```

[1] 2430

```
1 kovariance <- cov(  
2   x = data_priklad_vztahu_kovariance$delka_ploutve_r  
3   y = data_priklad_vztahu_kovariance$hmotnost_g  
4 )  
5 kovariance
```

[1] 2430

# Záleží na jednotkách?

Stejní tučňáci. Jiná jednotka.

**V milimetrech a gramech**

Kovariance: 9 824 (mm·g)

**V centimetrech a kilogramech**

Kovariance: 0,982 (cm·kg)

Směr vztahu se nezměnil, ale číslo ano. Proto chceme **bezrozměrný souhrn**: korelaci.

# Korelace

# Dvě čísla, která budeme používat

## PEARSONOVA KORELACE

- shrnuje lineární vztah
- bezrozměrná, v rozsahu  $-1$  až  $1$
- `cor(..., method = "pearson")`


## SPEARMANOVA KORELACE

- sleduje pořadí hodnot (rank)
- odolnější vůči zakřivení a odlehlým bodům
- `cor(..., method = "spearman")`


Obě čísla jsou **doplňěk ke grafu**, ne jeho náhrada.

# Kalibrační galerie


$r \approx 0,20$




$r \approx 0,50$



$r \approx 0,80$




$r \approx 0,95$



Naše tučňáci:  $r = 0,87$


# Záporná korelace



Záporné  $r$  (-0,89) | vyšší nadmořská výška → nižší průměrná teplota.

# Čtyři tučňáci v kódu

```
1 vec_delka_ploutve_mm <-  
2   c(186, 191, 197, 204)  
3  
4 vec_hmotnost_g <-  
5   c(3800, 3920, 4300, 4480)  
6  
7 cor(  
8   x = vec_delka_ploutve_mm,  
9   y = vec_hmotnost_g,  
10  method = "pearson"  
11 )  
12  
13 cor(  
14   x = vec_delka_ploutve_mm,  
15   y = vec_hmotnost_g,  
16   method = "spearman"  
17 )
```



## VÝSTUP

Pearson: [1] 0,98

Spearman: [1] 1,00

# Všichni tučňáci v kódu

## Pearsonova korelace

```
1 cor(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   method = "pearson"  
5 )
```

### VÝSTUP

[1] 0,87

## Spearmanova korelace

```
1 cor(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   method = "spearman"  
5 )
```

### VÝSTUP

[1] 0,84

Pearson zdůrazňuje linearitu, Spearman pořadí hodnot.

Ve které ze čtyř situací by se hodnoty Pearsona a Spearmana lišily nejvíce?

**Silný lineární vztah**

Obě čísla by se shodla — vztah je přímočarý.

**Žádná zřetelná souvislost**


Obě čísla by byla nízká.

**Monotónní, ale zakřivený vztah**

Pořadí sedí, ale linearita ne.





Než hlasujeme: přesvědčte souseda, která situace nejvíc rozdělí Pearsona a Spearmana.

# Příklad



Pearson: 0,67 / Spearman: 0,86 — pořadí sedí, ale linearita ne úplně.

# Čtyři situace korelace



# Co nám to říká právě o tučňácích?

*Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?*

Pearson i Spearman vyšly podobně

Pearson: 0,87, Spearman: 0,84.

Vztah je rostoucí a dobře shrnutelný jedním číslem.

Korelace neřekne, odkud vztah pochází

Část vztahu může souviset s druhem nebo celkovou velikostí těla.

# Korelace není kauzalita



# Korelace ukazuje asociaci, ne příčinu

## **SPOLEČNÁ ZMĚNA DVOU PROMĚNNÝCH**

Korelace popisuje, zda se dvě proměnné mění společně.

## **SAMA NEODDĚLÍ PŘÍČINU**

Korelace sama neodliší přímý efekt od sdílené příčiny.

# Jak vybrat první graf?

# Tři dvojice, tři různé otázky

**Délka ploutve × hmotnost**

**Druh tučňáka × hmotnost**

**Druh tučňáka × ostrov**

**SKUPINKA 3–4 · 2 MIN**

Ke každé dvojici navrhnete první graf a jednou větou zdůvodníte, co z něj chcete přechít.

# Rozhodovací mapa

| Proměnná A    | Proměnná B    | První poctivý pohled                 | Co z něj čteme                    |
|---------------|---------------|--------------------------------------|-----------------------------------|
| kvantitativní | kvantitativní | bodový graf                          | směr, tvar, těsnost, odlehlé body |
| kvantitativní | kategoriální  | body ve skupinách;<br>boxplot + body | rozdíly a překryv<br>rozdělení    |
| kategoriální  | kategoriální  | tabulka nebo sloupce<br>počtů/podílů | složení kombinací kategorií       |

Typy proměnných zúží možnosti. Biologická otázka rozhodne, co má graf zvýraznit.

# Tři první pohledy

## DVĚ HODNOTY

**Body:** jaký je směr, tvar a rozptyl?

## HODNOTA A SKUPINA

**Body + souhrn:** jak se skupiny liší a překrývají?

## DVĚ SKUPINY


**Počty nebo podíly:** kterou informaci potřebujeme?

## CO NESMÍME SKRÝT?

Boxplot může skrýt tvar a velikost vzorku. Podíly mohou skrýt počty. Hezčí graf proto není automaticky poctivější první graf.

**Co d'ál?**

# Co přidá model?



Přímka přidá **odhad efektu**: o kolik gramů se typicky mění hmotnost na každý 1 mm délky ploutve? To bude L03.

# Shrnutí

- Pro dvě numerické proměnné je první volbou bodový graf.
- Z grafu čteme současně směr vztahu i šířku rozptylu.
- Korelace vztah shrne číslem, ale nenahradí samotný graf.
- Viditelný vzor ještě není důkaz efektu.
- Model přidá velikost efektu a nejistotu.

### **CO JEŠTĚ POTŘEBUJEME?**

Co nám schází k tomu, abychom z viditelného vzoru přešli k přesnějšímu tvrzení o velikosti efektu a nejistotě?

- a. Větší dataset a více bodů v grafu.
- b. Model: v L03 přidá odhad efektu, v L04 jeho interval spolehlivosti.
- c. Silnější korelaci, aby bylo číslo přesvědčivější.

### **ŘEKNĚTE SOUSEDovi JEDNOU VĚTOU**

Co model přidá, co korelace neumí?