

Vztahy dvou proměnných a vizualizace

Biostatistika


 Ondřej Mottl

Moodle

Pomůže nám druhá proměnná?

NAŠE BIOLOGICKÁ OTÁZKA

Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?



Ilustrace: Allison Horst

Výsledky učení

Po dnešní přednášce budete schopni:

- přečíst první bodový graf pro dvě numerické proměnné
- vysvětlit, co nám ukáže rozptyl a co přidá korelace
- zvolit vhodný první graf podle typu dvojice proměnných
- rozlišit mezi viditelným vzorem v datech a silnějším tvrzením o efektu

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Potom společně projdeme správné odpovědi.

Který z uvedených druhů spí podle tabulky nejdéle?

Druh (species)	Spánek za den (h)
Cheetah	12.1
Owl monkey	17.0
Mountain beaver	14.4
Greater short-tailed shrew	14.9

Cheetah

Owl monkey

Mountain beaver


Greater short-tailed shrew

SPRÁVNÁ ODPOVĚĎ

: Owl monkey

Porovnáme hodnoty ve sloupci Spánek za den (h). Nejvyšší hodnota je 17.0 h v řádku Owl monkey.

Ve kterém intervalu délky spánku je podle histogramu nejvíce zastoupených druhů?



10–12 h

12–14 h

8–10 h

16–18 h

SPRÁVNÁ ODPOVĚĎ

: 8–10 h

Nejvyšší sloupec stojí nad intervalem 8–10 h. Poloha sloupce na vodorovné ose určuje interval spánku; jeho výška vyjadřuje počet druhů v tomto intervalu.

Jaká je podle výstupu průměrná délka spánku devíti druhů?

```
vec_spanek_deviti <- c(
  2.9, 3.8, 4.0, 8.0, 8.4,
  9.1, 9.7, 10.1, 12.5
)

mean(x = vec_spanek_deviti)
# [1] 7.611111

median(x = vec_spanek_deviti)
# [1] 8.4
```

SPRÁVNÁ ODPOVĚĎ

: 7.611111 h

Průměr vypočítává funkce `mean()`, která vrácí 7.611111 h. Funkce `median()` vrácí 8.4 h; hodnoty 4.0 h a 9.1 h jsou jednotlivá pozorování ve vektoru.

Od jedné proměnné ke dvěma

V MINULÉ LEKCI JSME ČETLI JEDNU PROMĚNNOU

Z tabulky, histogramu nebo číselného souhrnu jsme zjišťovali, jak vypadají hodnoty jedné proměnné.

DNES MUSÍME ZACHOVAT DVOJICE

Jak zobrazíme délku ploutve a hmotnost tak, aby bylo vidět, které dvě hodnoty patří stejnému tučňákovi?

Diskuze se sousedem

NAŠE BIOLOGICKÁ OTÁZKA


Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?

Jak by podle vás mohl vypadat graf pro zodpovězení této otázky?

30 s přemýšlení — pak sdílejte svůj odhad se sousedem.


Naše data

```
1 vec_delka_ploutve_mm <-  
2   c(  
3     186, # tučňák 1  
4     191 # tučňák 2  
5   )  
6  
7 vec_hmotnost_g <-  
8   c(  
9     3800, # tučňák 1  
10    3920 # tučňák 2  
11  )  
12  
13 plot(  
14   x = vec_delka_ploutve_mm,  
15   y = vec_hmotnost_g,  
16   xlab = "Délka ploutve (mm)",  
17   ylab = "Tělesná hmotnost (g)",  
18   pch = 16  
19 )
```




Naše data

```
1 vec_delka_ploutve_mm <-  
2   c(  
3     186, # tučňák 1  
4     191, # tučňák 2  
5     197, # tučňák 3  
6     204 # tučňák 4  
7   )  
8  
9 vec_hmotnost_g <-  
10  c(  
11    3800, # tučňák 1  
12    3920, # tučňák 2  
13    4300, # tučňák 3  
14    4480 # tučňák 4  
15  )  
16  
17 plot(  
18   x = vec_delka_ploutve_mm,  
19   y = vec_hmotnost_g,  
20   xlab = "Délka ploutve (mm)",  
21   ylab = "Tělesná hmotnost (g)",  
22   pch = 16
```




Naše data

```
1 plot(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   xlab = "Délka ploutve (mm)",  
5   ylab = "Tělesná hmotnost (g)",  
6   pch = 16  
7 )
```




Co už v tomto grafu vidíme?




- **Směr**: rostoucí
- **Rozptyl**: pořád široký
- **Závěr**: vzor vidíme, efekt zatím netvrdíme

Stejná data, jiné osy




Délka ploutve na ose x




Hmotnost na ose x

Rozptyl čteme ve dvou směrech



Podobná délka ploutve, různá
hmotnost



Podobná hmotnost, různá délka
ploutve

Když čteme bodový graf, díváme se současně na **směr vztahu** i na to, jak široký oblak zůstává v obou směrech.

Vracíme se k biologické otázce

Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?

Signál

Delší ploutve **bývají spojeny** s vyšší hmotností.

Rozptyl

Vztah **není** dokonale těsný.

POZOR

Vzor v grafu ještě není model, efekt ani nejistota.


CO UŽ MŮŽEME TVRDIT?

Která formulace je v této chvíli nejlepší?

- a. V grafu je vidět vztah, takže jsme prokázali efekt.
- b. V datech je vidět biologicky smysluplný vzor, který chceme popsat přesněji.
- c. Protože body neleží na jedné přímce, mezi proměnnými žádný vztah není.

Než hlasujeme: přesvědčte souseda, proč jste vybrali svoji možnost.


Stejná data, ale s druhem



Co se po obarvení změnilo?

BIOLOGICKÁ LOGIKA PLATÍ I PO OBARVENÍ PODLE DRUHU

- **Směr** oblaku zůstává kladný
 - *větší tučňák má delší ploutev.*
- **Rozptyl** má biologickou strukturu
 - Část variability pochází z míchání více druhů



Kdybychom chtěli jedno číslo pro souhrn všech dat?

CO BY TAKOVÉ ČÍSLO MUSELO UMĚT?


Směr + **těsnost** + stejné měřítko pro různé jednotky

ŘEKNĚTE SOUSEDОВI ASPOŇ JEDNU VLASTNOST

30 s každý — pak porovnejte, co jste vymysleli.


Kovariance

Nejprve průměry grafu




Střed grafu určíme dvěma průměry: délka 200.9 mm, hmotnost 4202 g.

Jeden bod pod lupou



BOD NAD PRŮMĚREM V OBOU PROMĚNNÝCH

Stejné znaménko odchylek → **kladný** příspěvek.



Ve které další části grafu budou součiny také kladné?



II. a III. kvadrant

Vpravo nahoře a vlevo dole — obě odchylky mají vždy stejné znaménko.

I. a IV. kvadrant


Vlevo nahoře a vpravo dole — odchylky mají opačná znaménka.

Všechny čtyři stejně

Na poloze vůči středu nezáleží.

Než hlasujeme: vysvětlíte sousedovi znaménka obou odchylek v jedné možnosti.

Projdeme čtyři tučňáky ručně



Délka	Hmotnost	Délka odch.	Hmotnost odch.
186	3800	-8.5	-325
191	3920	-3.5	-205
197	4300	2.5	175
204	4480	9.5	355

Průměry:

Délka ploutve: **194.5** mm

Hmotnost: **4125** g

Kovariance je “průměr součinů odchylek”

kovariance = **součet součinů odchylek** / (**počet pozorování** - 1)

Kovariance sčítá, jestli body leží převážně v kladných nebo záporných částech grafu.

Délka odch.	Hmotnost odch.	Součin
-8.5	-325	2762.5
-3.5	-205	717.5
2.5	175	437.5
9.5	355	3372.5

součet součinů odchylek = 7290

počet pozorování - 1 = 3

kovariance = $7290 / 3 = \mathbf{2430 \text{ mm} \cdot \text{g}}$

Prakticky stejné číslo nám dá funkce `cov()`.

```
1 soucin <- sum(  
2   data_priklad_vztahu_kovariance$soucin_odchylek  
3 )  
4 pocet_pozorovani_minus_one <-  
5   nrow(data_priklad_vztahu_kovariance) - 1  
6 kovariance <-  
7   vec_soucin / pocet_pozorovani_minus_one  
8 kovariance
```

[1] 2430

```
1 kovariance <- cov(  
2   x = data_priklad_vztahu_kovariance$delka_ploutve_r  
3   y = data_priklad_vztahu_kovariance$hmotnost_g  
4 )  
5 kovariance
```

[1] 2430

Záleží na jednotkách?

Stejní tučňáci. Jiná jednotka.

V milimetrech a gramech

Kovariance: 9 824 (mm·g)

V centimetrech a kilogramech

Kovariance: 0,982 (cm·kg)

Směr vztahu se nezměnil, ale číslo ano. Proto chceme **bezrozměrný souhrn**: korelaci.

Korelace

Dvě čísla, která budeme používat

PEARSONOVA KORELACE

- shrnuje lineární vztah
- bezrozměrná, v rozsahu -1 až 1
- `cor(..., method = "pearson")`


SPEARMANOVA KORELACE

- sleduje pořadí hodnot (rank)
- odolnější vůči zakřivení a odlehlým bodům
- `cor(..., method = "spearman")`


Obě čísla jsou **doplňk ke grafu**, ne jeho náhrada.

Kalibrační galerie


$r \approx 0,20$




$r \approx 0,50$



$r \approx 0,80$




$r \approx 0,95$



Naše tučňáci: $r = 0,87$


Záporná korelace



Záporné r (-0,89) | vyšší nadmořská výška → nižší průměrná teplota.

Čtyři tučňáci v kódu

```
1 vec_delka_ploutve_mm <-  
2   c(186, 191, 197, 204)  
3  
4 vec_hmotnost_g <-  
5   c(3800, 3920, 4300, 4480)  
6  
7 cor(  
8   x = vec_delka_ploutve_mm,  
9   y = vec_hmotnost_g,  
10  method = "pearson"  
11 )  
12  
13 cor(  
14   x = vec_delka_ploutve_mm,  
15   y = vec_hmotnost_g,  
16   method = "spearman"  
17 )
```



VÝSTUP

Pearson: [1] 0,98

Spearman: [1] 1,00

Všichni tučňáci v kódu

Pearsonova korelace

```
1 cor(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   method = "pearson"  
5 )
```

VÝSTUP

[1] 0,87

Spearmanova korelace

```
1 cor(  
2   x = data_tucnaci$delka_ploutve_mm,  
3   y = data_tucnaci$hmotnost_g,  
4   method = "spearman"  
5 )
```

VÝSTUP

[1] 0,84

Pearson zdůrazňuje linearitu, Spearman pořadí hodnot.

Ve které ze čtyř situací by se hodnoty Pearsona a Spearmana lišily nejvíce?

Silný lineární vztah

Obě čísla by se shodla — vztah je přímočarý.

Žádná zřetelná souvislost


Obě čísla by byla nízká.

Monotónní, ale zakřivený vztah

Pořadí sedí, ale linearita ne.





Než hlasujeme: přesvědčte souseda, která situace nejvíc rozdělí Pearsona a Spearmana.

Příklad



Pearson: 0,67 / Spearman: 0,86 — pořadí sedí, ale linearita ne úplně.

Čtyři situace korelace



Co nám to říká právě o tučňácích?

Mají tučňáci s delší ploutví také vyšší tělesnou hmotnost?

Pearson i Spearman vyšly podobně

Pearson: 0,87, Spearman: 0,84.

Vztah je rostoucí a dobře shrnutelný jedním číslem.

Korelace neřekne, odkud vztah pochází

Část vztahu může souviset s druhem nebo celkovou velikostí těla.

Korelace není kauzalita



Korelace ukazuje asociaci, ne příčinu

SPOLEČNÁ ZMĚNA DVOU PROMĚNNÝCH

Korelace popisuje, zda se dvě proměnné mění společně.

SAMA NEODDĚLÍ PŘÍČINU

Korelace sama neodliší přímý efekt od sdílené příčiny.

Jak vybrat první graf?

Tři dvojice, tři různé otázky

Délka ploutve × hmotnost

Druh tučňáka × hmotnost

Druh tučňáka × ostrov

SKUPINKA 3–4 · 2 MIN

Ke každé dvojici navrhnete první graf a jednou větou zdůvodníte, co z něj chcete přechít.

Rozhodovací mapa

Proměnná A	Proměnná B	První poctivý pohled	Co z něj čteme
kvantitativní	kvantitativní	bodový graf	směr, tvar, těsnost, odlehlé body
kvantitativní	kategoriální	body ve skupinách; boxplot + body	rozdíly a překryv rozdělení
kategoriální	kategoriální	tabulka nebo sloupce počtů/podílů	složení kombinací kategorií

Typy proměnných zúží možnosti. **Biologická otázka** rozhodne, co má graf zvýraznit.

Tři první pohledy

DVĚ HODNOTY

Body: jaký je směr, tvar a rozptyl?

HODNOTA A SKUPINA

Body + souhrn: jak se skupiny liší a překrývají?

DVĚ SKUPINY

Počty nebo podíly: kterou informaci potřebujeme?

CO NESMÍME SKRÝT?

Boxplot může skrýt tvar a velikost vzorku. Podíly mohou skrýt počty. Hezčí graf proto není automaticky poctivější první graf.

Jak vybrat první graf?

Typy proměnných zúží volbu grafu

Délka ploutve × hmotnost

Druh tučnáka × hmotnost

Druh tučnáka × ostrov (habitat)

SKUPINKA 3-4 - 2 MIN

Ke každé dvojici přiřad'te graf a připravte si jedno zdůvodnění.

Kvantitativní × kvantitativní


Délka ploutve × hmotnost

Obě proměnné mají číselnou osu. Každý jedinec může být jedním bodem.

K×K: body


Body

každý tučňák je jeden bod



Když mají obě proměnné **číselné hodnoty**, první volbou je **bodový graf**.

K×K: přidáme kategorii barvou




Barva nepřidala novou osu. Přidala **novou otázku**: je vztah stejný ve všech skupinách?

K×K: když se body překrývají

Hustota

kde se body nejvíc hromadí



Hustota odpovídá na jinou otázku: kde je dat nejvíc?

K×K: zvolte první graf

PRVNÍ ČTENÍ

Co ukážu, když chci vztah
nejdřív jen vidět?

SKUPINY

Co přidám, když
podezírám rozdíly mezi
druhy?

PŘEKRYV

Co změním, když mám
tisíce bodů?

Kvantitativní × kategoriální


Hmotnost × druh

Jedna proměnná je číslo, druhá vytváří skupiny. Už nečteme oblak bodů ve dvou číselných osách.

K×Kat: body ve skupinách

Body ve skupinách

neztrácíme jednotlivá pozorování




Body ve skupinách jsou často nejlepší první graf, protože **nic neskrývají**.

K×Kat: boxplot + body


Boxplot + body

rychlý souhrn a kontrola dat




Boxplot je rychlý souhrn, ale samotný boxplot může **skrýt tvar dat**.

K×Kat: violin + boxplot




Violin ukáže tvar rozložení; boxplot uvnitř dá rychlý souhrn.

K×Kat: histogram



Histogram ukazuje **skutečné počty** tučňáků v intervalech hmotnosti.

K×Kat: skládaná hustota



Skládaná hustota neukazuje počty. Ukazuje **relativní složení** druhů podél hmotnosti.

Který graf byste udělali jako první?

Body ve skupinách

Vidíme každého tučňáka.

Boxplot

Rychleji čteme typickou hodnotu a rozptyl.

Violin / histogram

Lépe čteme tvar nebo počty v intervalech.

Kategoriální × kategoriální


Druh × ostrov

Obě proměnné jsou skupiny. Ted' čteme počty nebo podíly v kombinacích kategorií.

Kat×Kat: waffle plot


Waffle plot

každý čtvereček je jeden tučňák




Waffle plot ukáže počty jako jednotky: vidíme složení i velikost skupin.

Kat×Kat: skupinové sloupce



Skupinové sloupce usnadní porovnání absolutních počtů mezi ostrovy.

Kat×Kat: skládané podíly




Podíly odpovídají na otázku **složení**, ne na otázku velikosti vzorku.

Kat×Kat: bublinové počty

Bublinové počty

stejná tabulka jako plocha



Bublíny jsou efektní, ale **porovnávání ploch** je pro oko těžší než **porovnávání délek**.

Kat×Kat: počty nebo podíly?

POČTY

Kdy potřebujeme vědět, kolik pozorování opravdu máme?

PODÍLY

Kdy nás zajímá složení skupiny bez ohledu na její velikost?

Co rozhoduje?

Číselná osa

Chceme číst vztah dvou hodnot.

Skupiny

Chceme porovnat rozložení mezi kategoriemi.

Kombinace kategorií

Chceme počty nebo podíly.


Nejdřív se zeptejte: jakého typu je proměnná A a jakého typu je proměnná B?

Shrnutí základních vizualizací

Proměnná A	Proměnná B	Možné typy grafu
kvantitativní	kvantitativní	bodový graf; bodový graf s barvou, přímkou nebo hustotou
kvantitativní	kategoriální	body ve skupinách; boxplot; violin plot
kategoriální	kategoriální	tabulka četností; waffle plot; skupinové nebo skládané sloupce

Co dál?

Co přidá **model**?



Přímka přidá **odhad efektu**: o kolik gramů se typicky mění hmotnost na každý 1 mm délky ploutve? To bude téma následující lekce.

Shrnutí

- Pro dvě numerické proměnné je první volbou **bodový graf**.
- Z grafu čteme současně **směr vztahu** i **šířku rozptylu**.
- **Korelace** vztah shrne číslem, ale nenahradí samotný graf.
- Viditelný vzor ještě není důkaz **efektu**.
- **Model** přidá velikost efektu a jeho nejistotu.

CO JEŠTĚ POTŘEBUJEME?

Co nám schází k tomu, abychom z viditelného vzoru přešli k přesnějšímu tvrzení o velikosti efektu a nejistotě?

- a. Větší dataset a více bodů v grafu.
- b. Model: v následující lekci přidá odhad efektu a potom jeho interval spolehlivosti.
- c. Silnější korelaci, aby bylo číslo přesvědčivější.

ŘEKNĚTE SOUSEDovi JEDNOU VĚTOU

Co model přidá, co korelace neumí?